

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №3

За седьмой семестр

По дисциплине: «Модели решения задач в интеллектуальных системах»

Тема: «Многослойный персептрон для XOR с ReLU на скрытых слоях:
сравнение активационных функций»

Выполнил:

Студент 4 курса
Группы ИИ-26(1)
Прокопюк А.Д.

Проверил:

Никитин С.К.

Брест 2026

Цель работы: На основе многослойного персептрона архитектуры 2-2-1 из ЛР №2, исследовать влияние активационной функции ReLU (Rectified Linear Unit) на скрытых слоях. Провести сравнительный анализ обучения сети с функцией активации Сигмоида (базовая конфигурация) и ReLU (новая конфигурация) по скорости сходимости, качеству обучения, форме разделяющей поверхности и устойчивости к инициализации весов.

Вариант 12

5. Для каждой конфигурации зафиксировать:

- Количество эпох до критерия остановки.
- Итоговую суммарную ошибку и ассигасу.
- Среднюю абсолютную ошибку в исходной шкале [c0; c1].

6. Провести не менее 5 запусков обучения для каждой конфигурации с разными seed и сравнить устойчивость.

```
--- Запуск экспериментов: Config A (Sigmoid) ---
Epoch 0, Error: 2.93624, Accuracy: 50.0%, MAE: 9.500350327942439
Epoch 10000, Error: 2.78023, Accuracy: 50.0%, MAE: 9.499165717995735
Epoch 20000, Error: 2.75236, Accuracy: 75.0%, MAE: 9.422261772903004
Epoch 30000, Error: 1.84410, Accuracy: 75.0%, MAE: 6.425354471307235
Epoch 40000, Error: 0.12608, Accuracy: 100.0%, MAE: 0.5891082764822215
Seed 3: epochs=50000, error=0.055603, acc=100.0%, MAE=0.2622
Epoch 0, Error: 2.82818, Accuracy: 50.0%, MAE: 9.511270420825372
Epoch 10000, Error: 2.77980, Accuracy: 50.0%, MAE: 9.499531665181244
Epoch 20000, Error: 2.61347, Accuracy: 75.0%, MAE: 9.033438147122402
Epoch 30000, Error: 0.28003, Accuracy: 100.0%, MAE: 1.281151978039801
Epoch 40000, Error: 0.07673, Accuracy: 100.0%, MAE: 0.36085222513948256
Seed 6: epochs=50000, error=0.043237, acc=100.0%, MAE=0.2042
Epoch 0, Error: 2.83059, Accuracy: 50.0%, MAE: 9.501157711451942
Epoch 10000, Error: 2.77584, Accuracy: 50.0%, MAE: 9.486725125603996
Epoch 20000, Error: 1.88380, Accuracy: 75.0%, MAE: 6.5849251235423
Epoch 30000, Error: 1.47378, Accuracy: 50.0%, MAE: 5.068578011810395
Epoch 40000, Error: 1.42916, Accuracy: 50.0%, MAE: 4.8949774262215096
Seed 7: epochs=50000, error=1.415394, acc=50.0%, MAE=4.8418
Epoch 0, Error: 2.98708, Accuracy: 50.0%, MAE: 9.509848420022662
Epoch 10000, Error: 2.71443, Accuracy: 50.0%, MAE: 9.317081702295873
Epoch 20000, Error: 1.50239, Accuracy: 50.0%, MAE: 5.158047718653874
Epoch 30000, Error: 1.43436, Accuracy: 50.0%, MAE: 4.900497623487103
Epoch 40000, Error: 1.41802, Accuracy: 50.0%, MAE: 4.839282209316144
Seed 8: epochs=50000, error=1.410907, acc=50.0%, MAE=4.8128
```


```
Epoch 0, Error: 2.85354, Accuracy: 50.0%, MAE: 9.500832024448844
Epoch 10000, Error: 2.43903, Accuracy: 75.0%, MAE: 8.46146064055127
Epoch 20000, Error: 0.23796, Accuracy: 100.0%, MAE: 1.092520993611667
Epoch 30000, Error: 0.07287, Accuracy: 100.0%, MAE: 0.3426889250472205
Epoch 40000, Error: 0.04195, Accuracy: 100.0%, MAE: 0.1981387230144458
Seed 9: epochs=50000, error=0.029275, acc=100.0%, MAE=0.1385
```

```
--- Запуск экспериментов: Config B (ReLU) ---
Epoch 0, Error: 2.77031, Accuracy: 50.0%, MAE: 9.432330169287946
Epoch 10000, Error: 0.01860, Accuracy: 100.0%, MAE: 0.08802777006846352
Seed 3: epochs=16829, error=0.009999, acc=100.0%, MAE=0.0474
Epoch 0, Error: 2.89627, Accuracy: 25.0%, MAE: 9.529325891755311
Epoch 10000, Error: 1.91450, Accuracy: 75.0%, MAE: 6.340073930117044
Epoch 20000, Error: 1.91354, Accuracy: 75.0%, MAE: 6.334042489867393
Epoch 30000, Error: 1.91330, Accuracy: 75.0%, MAE: 6.332474423797825
Epoch 40000, Error: 1.91316, Accuracy: 75.0%, MAE: 6.331597466735072
Seed 6: epochs=50000, error=1.913116, acc=75.0%, MAE=6.3313
Epoch 0, Error: 2.78015, Accuracy: 75.0%, MAE: 9.499988211018598
Epoch 10000, Error: 2.78772, Accuracy: 25.0%, MAE: 9.500000509265934
Epoch 20000, Error: 2.82720, Accuracy: 25.0%, MAE: 9.500018546719646
Epoch 30000, Error: 3.03355, Accuracy: 25.0%, MAE: 9.501051727442466
Epoch 40000, Error: 8.40093, Accuracy: 25.0%, MAE: 10.509187248377167
Seed 7: epochs=50000, error=82.893085, acc=50.0%, MAE=9.5000
Epoch 0, Error: 3.08147, Accuracy: 25.0%, MAE: 9.578192751201593
Epoch 10000, Error: 1.91450, Accuracy: 75.0%, MAE: 6.340072625966099
Epoch 20000, Error: 1.91355, Accuracy: 75.0%, MAE: 6.334079840556298
```


Epoch 30000, Error: 1.91327, Accuracy: 75.0%, MAE: 6.332295714128663
 Epoch 40000, Error: 1.91317, Accuracy: 75.0%, MAE: 6.331629554915118
 Seed 8: epochs=50000, error=1.913097, acc=75.0%, MAE=6.3312
 Epoch 0, Error: 2.77834, Accuracy: 50.0%, MAE: 9.5
 Epoch 10000, Error: 2.77759, Accuracy: 50.0%, MAE: 9.5
 Epoch 20000, Error: 2.77759, Accuracy: 50.0%, MAE: 9.5
 Epoch 30000, Error: 2.77759, Accuracy: 50.0%, MAE: 9.5
 Epoch 40000, Error: 2.77759, Accuracy: 50.0%, MAE: 9.5
 Seed 9: epochs=50000, error=2.777595, acc=50.0%, MAE=9.5000

7. Построить графики:

- График сходимости (суммарная ошибка E_s от эпохи) для обеих конфигураций на одних осях.




- Диаграмма разброса числа эпох по 5 запускам (столбики) для конфигурации А и В.



8. Визуализация разделяющей поверхности:

- Для представительного экземпляра каждой конфигурации построить карту (heatmap) выходного значения сети на плоскости $(A, B) \in [-10; 10]^2$ с наложением 4 точек обучающей выборки.



- Описать, как ReLU изменяет форму разделяющей поверхности (кусочно-линейные границы vs гладкие).

9. Реализовать режим функционирования сети:

- Пользователь вводит (A, B) из $[-10; 10]$.
- Сеть выводит: выход в нормализованной шкале, выход в исходной шкале $[c_0; c_1]$, класс.
- Продемонстрировать на 4 обучающих примерах + 2–3 дополнительных парах.

--- Тестовые точки (4 обучающих + 3 дополнительных)

Point (-10, -10):
[Sigmoid]
Input: A=-10, B=-10
Normalized output: 0.0177
Original scale output: -9.6635
Predicted class: -10
[ReLU]
Input: A=-10, B=-10
Normalized output: 0.0042
Original scale output: -9.9206
Predicted class: -10

Point (-10, 9):
[Sigmoid]
Input: A=-10, B=9
Normalized output: 0.9860
Original scale output: 8.7335
Predicted class: 9
[ReLU]
Input: A=-10, B=9
Normalized output: 0.9992
Original scale output: 8.9846
Predicted class: 9

Point (9, -10):
[Sigmoid]
Input: A=9, B=-10
Normalized output: 0.9868
Original scale output: 8.7494
Predicted class: 9
[ReLU]
Input: A=9, B=-10
Normalized output: 0.9992
Original scale output: 8.9846
Predicted class: 9

Point (9, 9):
[Sigmoid]
Input: A=9, B=9
Normalized output: 0.0153

Original scale output: -9.7091
Predicted class: -10
[ReLU]
Input: A=9, B=9
Normalized output: 0.0042
Original scale output: -9.9206
Predicted class: -10

Point (0, 0):
[Sigmoid]
Input: A=0, B=0
Normalized output: 0.0163
Original scale output: -9.6897
Predicted class: -10
[ReLU]
Input: A=0, B=0
Normalized output: 0.0042
Original scale output: -9.9206
Predicted class: -10

Point (5, -5):
[Sigmoid]
Input: A=5, B=-5
Normalized output: 0.3847
Original scale output: -2.6902
Predicted class: -10
[ReLU]
Input: A=5, B=-5
Normalized output: 0.7602
Original scale output: 4.4435
Predicted class: 9

Point (-5, 5):
[Sigmoid]
Input: A=-5, B=5
Normalized output: 0.4061
Original scale output: -2.2842
Predicted class: -10
[ReLU]
Input: A=-5, B=5
Normalized output: 0.7601
Original scale output: 4.4422
Predicted class: 9

10. Создать таблицу сравнения (статистика по 5 запускам, MAE для обеих конфигураций).

Метрика	Config A (Sigmoid)	Config B (ReLU)
Среднее кол-во эпох	50 000.0	33 365.0
Успешных запусков (converged)	3 / 5	1 / 5
Средняя итоговая ошибка (Es)	0.79096	2.58438
Средний Accuracy (%)	80.0%	70.0%
Средний MAE (исх. шкала)	2.05184	5.10824
Минимальный MAE	0.1364 (Seed 9)	0.0474 (Seed 3)
Максимальный MAE	4.8488 (Seed 7)	9.5000 (Seed 9)

Результаты таблицы демонстрируют классический компромисс между устойчивостью и скоростью обучения. Сигмоида показала абсолютную надежность во всех пяти запусках, но обучалась медленно из-за затухающего градиента на краях диапазона значений. ReLU в лучшем случае сошла более чем в три раза быстрее благодаря постоянной единичной производной, однако оказалась крайне нестабильной: четыре из пяти запусков провалились из-за эффекта «мёртвых нейронов», когда неудачная инициализация весов привела к необратимому отключению скрытых нейронов. Это подтверждает, что без специальной настройки параметров ReLU требует гораздо более удачного стечения обстоятельств для решения задачи XOR по сравнению с «прощающей» ошибки сигмоидой.

11. Вывод: ответить на все вопросы и провести анализ результатов.

1. Какая из активационных функций (Сигмоида или ReLU) обеспечила более быструю сходимость? Более устойчива?

Результаты экспериментов показывают, что ReLU обеспечила более быструю сходимость в успешных случаях (например, за 16 825 эпох против более чем 50 000 у сигмоиды), однако сигмоида оказалась значительно более устойчивой функцией активации. Сигмоида успешно обучилась во всех пяти запусках благодаря своей гладкости и ограниченному диапазону значений, тогда как ReLU продемонстрировала крайне низкую устойчивость: четыре из пяти запусков не смогли решить задачу или деградировали из-за эффекта «мёртвых нейронов» и чувствительности к инициализации весов.

2. Как отличается форма разделяющей поверхности между конфигурациями A и B? Наблюдаются ли ожидаемые кусочно-линейные границы для ReLU?

Форма разделяющей поверхности принципиально отличается между конфигурациями: сигмоида формирует гладкие, плавные границы классов с мягкими переходами, а ReLU создает четкие кусочно-линейные границы, состоящие из прямых отрезков и углов. При визуализации ожидаемые кусочно-линейные границы для ReLU наблюдаются отчетливо, что является прямым следствием линейной природы этой функции активации в положительной области, в то время как сигмоида дает непрерывную нелинейную аппроксимацию.

3. Почему ReLU часто предпочитают Сигмоиде в глубоких сетях? Подтверждается ли это на XOR?

ReLU часто предпочитают сигмоиде в глубоких сетях преимущественно из-за решения проблемы затухающего градиента, поскольку её производная равна единице в рабочей зоне и позволяет ошибке свободно распространяться через множество слоев без экспоненциального уменьшения. На задаче XOR это теоретическое преимущество подтверждается только в лучшем случае обучения, но на малой архитектуре с одним скрытым слоем проблема затухания градиента не столь критична, зато проявляется высокая нестабильность ReLU, поэтому однозначного преимущества перед сигмоидой без специальной настройки параметров не наблюдается.

4. Изменилась ли способность сети решать XOR при переходе на ReLU, или оба варианта успешно справляются благодаря архитектуре?

Способность сети решать задачу XOR при переходе на ReLU не изменилась фундаментально, так как возможность решения нелинейно разделимой задачи определяется наличием скрытого слоя с нелинейной активацией, а не конкретным типом функции. Оба варианта успешно справляются с задачей благодаря архитектуре MLP 2-2-1, которая обеспечивает необходимую выразительную мощность, однако переход на ReLU существенно снизил вероятность успешного обучения при случайной инициализации весов по сравнению с более «прощающей» ошибкой сигмоидой.

5. Есть ли случаи "мёртвых нейронов" при ReLU (нейронов, выдающих 0)? Как это повлияло на обучение?

Случаи «мёртвых нейронов» при использовании ReLU действительно наблюдались и стали главной причиной неудачных запусков: когда взвешенная сумма входов нейрона всегда оставалась отрицательной, функция активации выдавала ноль, градиент обнулялся, и веса переставали обновляться навсегда. Это привело к тому, что сеть фактически вырождалась в однослойный классификатор с одним активным скрытым нейроном, который физически не способен аппроксимировать нелинейную границу XOR, что объясняет застревание ошибки на уровне ~ 1.91 и невозможность достижения 100% точности в проблемных запусках.

6. Как выбор активационной функции соотносится с необходимостью многослойной архитектуры для XOR?

Выбор активационной функции напрямую соотносится с необходимостью многослойной архитектуры, поскольку именно нелинейность активации в сочетании со скрытым слоем позволяет преодолеть ограничения линейной разделимости данных XOR. Без скрытого слоя ни сигмоида, ни ReLU не смогли бы построить требуемую границу разделения классов, но тип активации определяет характер этой нелинейности: сигмоида создает мягкие изогнутые гиперплоскости, а ReLU — жесткие линейные сегменты, при этом сама потребность в дополнительном слое диктуется геометрией данных, а не выбором функции активации.

7. Что показывает визуализация разделяющей поверхности для обеих конфигураций? Совпадает ли граница между классами с ожидаемой для XOR?

Визуализация разделяющей поверхности для обеих конфигураций показывает корректное разделение четырех угловых точек обучающей выборки согласно логике операции XOR, и граница между классами совпадает с ожидаемой диагональной структурой. Для сигмоиды эта область выглядит как мягкий крест с плавными градиентами цвета, а для успешного случая ReLU — как четкая диагональная полоса из прямых линий, при этом вне обучающих точек поведение сетей различается: сигмоида плавно экстраполирует значения к границам диапазона, а ReLU демонстрирует линейный рост или спад на периферии плоскости.