Министерство образования Республики Беларусь

Учреждение образования

«Брестский государственный технический университет»

Кафедра ИИТ

Лабораторная работа № 4

За седьмой семестр

По дисциплине «Модели решения задач в интеллектуальных системах»

Тема: «Многослойный персептрон для прогнозирования временного ряда: влияние размера окна и числа скрытых нейронов»

Выполнил:

Студент 4 курса

Группы ИИ-26

Ерошин Е.А.

Проверил:

Никитин С.К.

2026

Цель работы: на основе многослойного персептрона p–N–1 решить задачу прогнозирования временного ряда. Научиться формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовать влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.

Вариант: 3: a = 1.5, b = 0.4, c = 0.8, d = 0.9, p = 6, N = 5

Постановка задачи

Прогнозируемый ряд задаётся формулой: $x_k = a \cdot \cos(b \cdot k) + c \cdot \sin(d \cdot k), k = 0,1,2,\ldots,199$

Параметры a, b, c, d, размер окна p и число скрытых нейронов N берутся из таблицы варианта.

Первые 70 % точек (k = 0…139) образуют обучающий участок, остальные 30 % (k = 140…199) – тестовый участок. Сеть по p предыдущим значениям ряда предсказывает следующее: $x_k = F(x_{k-1}, x_{k-2}, \ldots, x_{k-p})$

Задачи лабораторной работы

1. Сгенерировать ряд по формуле варианта и построить его график с отметкой границы между обучающим и тестовым участками.
2. Нормализовать ряд по минимуму и максимуму **обучающего участка**: x_norm = (x - x_min) / (x_max - x_min). Записать формулу обратного пересчёта и использовать её при вычислении всех метрик в исходной шкале. **Объяснить**, почему min/max нельзя брать по всему ряду.
3. Сформировать обучающую и тестовую выборки методом скользящего окна размера p (вход – p значений, цель – следующее значение). Указать количество получившихся примеров в каждой выборке.
4. Реализовать многослойный персептрон p–N–1:
   - скрытый слой – сигмоида;
   - выходной слой – линейный (задача регрессии), f(s) = s;
   - функция потерь – MSE;
   - обучение – онлайн-режим, перемешивание порядка примеров в каждой эпохе;
   - вывести формулы градиентов для линейного выходного слоя и сигмоидного скрытого слоя и привести их в отчёте.
5. Критерий остановки: средняя по обучающей выборке ошибка $E_s \le E_e$, где $E_e = 10^{-4}$ (нормализованная шкала), либо достижение 20 000 эпох. Скорость обучения подобрать самостоятельно из диапазона 0.01–0.3 и обосновать выбор.
6. **Базовый эксперимент.** Обучить сеть с параметрами p и N из своего варианта. Зафиксировать число эпох, итоговую E_s, а также метрики на обучающем и тестовом участках **в исходной шкале**: MAE, RMSE и MAPE (если ряд проходит через ноль – вместо MAPE использовать sMAPE, и пояснить почему).

7. **Исследование окна.** При фиксированном N из варианта обучить сеть для p $\in$ {2, 4, p_вар, 2·p_вар}. Для каждого p выполнить по 5 запусков с разными seed и свести в таблицу: среднее и разброс числа эпох, среднее и разброс тестового MAE, число запусков, не достигших критерия остановки.
8. **Исследование скрытого слоя.** При фиксированном p из варианта обучить сеть для N $\in$ {1, 2, N_вар, 2·N_вар}. Выполнить ту же серию из 5 запусков и заполнить аналогичную таблицу.
9. **Многошаговый прогноз.** Для лучшей по тестовому MAE конфигурации выполнить рекурсивный прогноз на 30 шагов вперёд, начиная с k = 140: каждое предсказание подставляется в окно как входное значение для следующего шага. Построить график «эталон – рекурсивный прогноз» и график абсолютной ошибки в зависимости от номера шага. Определить, на каком шаге ошибка превышает 5 % от размаха ряда.
10. Построить графики:
    - ряд с границей train/test и одношаговым прогнозом сети на обоих участках на одних осях;
    - сходимость (Es от эпохи) для базовой конфигурации и для двух конфигураций из исследования окна на одних осях
      (логарифмическая шкала по Y);
    - диаграмма рассеяния «эталон – прогноз» на тестовом участке с диагональю y = x;
    - рекурсивный прогноз и рост ошибки по шагам (п. 9).
11. Реализовать режим функционирования: пользователь вводит p последовательных значений ряда в исходной шкале (либо номер k, с которого брать окно из ряда). Программа выводит:
    - нормализованные входы;
    - прогноз в нормализованной шкале (4 знака после запятой);
    - прогноз в исходной шкале;
    - истинное значение x(k) и абсолютную ошибку (если окно взято из ряда).

Продемонстрировать работу не менее чем на 3 окнах из обучающего участка, 3 окнах из тестового участка и 1–2 пользовательских окнах (в том числе с «выбросом»). 12. Вставить в отчет фото/скан рукописных расчётов. Вверху листа от руки должны быть написаны Ваша Фамилия, Инициалы, номер группы, вариант и дата выполнения: ○ Графическая схема пайплайна (Блок-схема). Составьте корректную цепочку обработки данных, используя предложенный набор блоков (приложение 1). Объясните свой выбор. ○ Ручной расчёт 1 шага обучения. На отдельном листе бумаги от руки распишите один полный шаг (Forward + Backward pass) для сети 3– 2–1 со следующими параметрами, привязанными к вашему варианту V:

- Входы: X = [0.2, 0.5, 0.8], Цель: d = 0.6

- Веса скрытого слоя: W11 = 0.05*V, W12 = -0.2, W21 = 0.3, W22 = 0.05*V, W31 = -0.1, W32 = 0.4 (b1=0.1, b2=-0.1)
- Веса выходного слоя: W_out1 = 0.5, W_out2 = -0.2*V (b_out = 0.2)

13. Сделать вывод: ответить на все вопросы ниже и проанализировать результаты.

Требования к реализации

- Скрытый слой – сигмоида, выходной слой – линейный. Веса инициализируются малыми случайными значениями, для воспроизводимости использовать фиксированный seed.
- Обучение – алгоритм обратного распространения в онлайн-режиме.
- Допускается использование NumPy и Matplotlib.
- Запрещено использование scikit-learn, PyTorch, TensorFlow и других MLфреймворков, а также готовых функций для скользящего окна и расчёта метрик из внешних библиотек (кроме NumPy).
- Код должен быть структурирован: отдельные функции для генерации ряда, нормализации, построения окон, прямого и обратного проходов, обучения, метрик, рекурсивного прогноза и режима функционирования.

Таблица вариантов

Ряд: $x_k = a \cdot \cos(b \cdot k) + c \cdot \sin(d \cdot k)$,
$k = 0 \ldots 199$, p – размер окна, N – число скрытых нейронов.

Вариант	a	b	c	d	p	N
3	1.5	0.4	0.8	0.9	6	5

Код программы: в электроном виде

Результат работы программы:

Остановка на эпохе 103, MSE: 0.000095

Результаты: MAE=0.0335, RMSE=0.0389, sMAPE=5.50%

ДЕМОНСТРАЦИЯ РЕЖИМА ФУНКЦИОНИРОВАНИЯ

--- Окно для k=50 ---

Исходное окно: [1.2304 1.2578 0.9265 0.7031 0.8449 1.191]

Нормализованные входы: [0.7703 0.7764 0.7026 0.6529 0.6845 0.7615]

Прогноз (норм. шкала): 0.7787

Прогноз (исх. шкала): 1.2683

Истинное значение x(50): 1.2928Абсолютная ошибка: 0.0246

--- Окно для k=80 ---
Исходное окно: [-0.8331 -0.5678 0.2657 1.3715 2.1726 2.207]
Нормализованные входы: [0.3109 0.37   0.5555 0.8017 0.98   0.9877]
Прогноз (норм. шкала): 0.8237
Прогноз (исх. шкала): 1.4701
Истинное значение x(80): 1.4544
Абсолютная ошибка: 0.0157

--- Окно для k=120 ---
Исходное окно: [0.6324 -0.5109 -1.6558 -2.2207 -1.9567 -1.1076]
Нормализованные входы: [0.6372 0.3827 0.1278 0.002 0.0608 0.2498]
Прогноз (норм. шкала): 0.4487
Прогноз (исх. шкала): -0.2143
Истинное значение x(120): -0.2188
Абсолютная ошибка: 0.0044

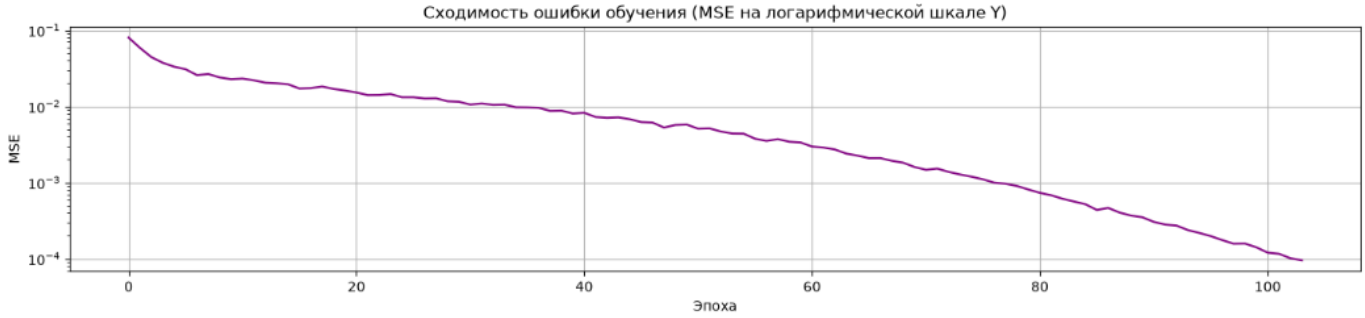
--- Окно для k=145 ---
Исходное окно: [0.4467 1.5438 2.2391 2.1283 1.277 0.1737]
Нормализованные входы: [0.5958 0.8401 0.9948 0.9702 0.7807 0.5351]
Прогноз (норм. шкала): 0.3556
Прогноз (исх. шкала): -0.6323
Истинное значение x(145): -0.6151
Абсолютная ошибка: 0.0172

--- Окно для k=170 ---
Исходное окно: [-1.3528 -2.0979 -2.1535 -1.3972 -0.1921 0.8552]
Нормализованные входы: [0.1953 0.0294 0.017 0.1854 0.4536 0.6868]
Прогноз (норм. шкала): 0.7899
Прогноз (исх. шкала): 1.3183
Истинное значение x(170): 1.3053
Абсолютная ошибка: 0.0130

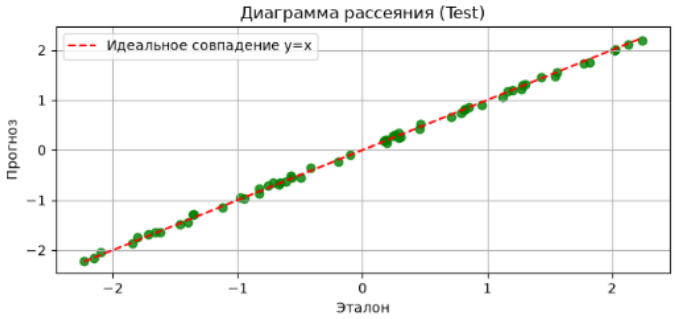
--- Окно для k=190 ---
Исходное окно: [0.2906 0.2611 0.1882 0.4596 1.1255 1.8204]
Нормализованные входы: [0.5611 0.5545 0.5383 0.5987 0.7469 0.9016]
Прогноз (норм. шкала): 0.9380
Прогноз (исх. шкала): 1.9839
Истинное значение x(190): 2.0178
Абсолютная ошибка: 0.0338

Process finished with exit code 0

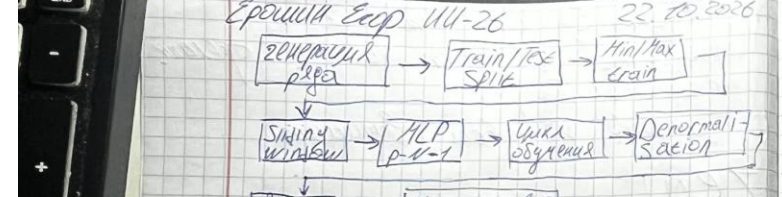

Одношаговый прогноз на всем интервале
Исходный ряд
Граница Train/Test (k=140)
Прогноз (Train)
Прогноз (Test)
x(k)
k


Сходимость ошибки обучения (MSE на логарифмической шкале Y)
MSE
Эпоха


Многошаговый прогноз (30 шагов)
Эталон
Рекурсивный прогноз
x(k)
Шаг прогноза


Диаграмма рассеяния (Test)
Идеальное совпадение y=x
Прогноз
Эталон

Ерошин Егор ИИ-26 22.10.2026



1. Вариант 3 ($V=3$)

Вход: $X=[x_1, x_2, x_3]=[0{,}2;\ 0{,}5;\ 0{,}8]$

Цель: $d=0{,}6$

Скорость обучения: $\eta=0{,}1$

Веса скрытого слоя ($3\to2$):

$w_{11}=0{,}05\cdot3=0{,}15$, $w_{12}=-0{,}2$

$w_{21}=0{,}3$, $w_{22}=0{,}05\cdot3=0{,}15$

$w_{31}=-0{,}1$, $w_{32}=-0{,}4$

Смещения: $b_1=0{,}1$, $b_2=-0{,}1$

Веса выходного слоя ($2\to1$):

$w_{вых1}=0{,}5$, $w_{вых2}=-0{,}2\cdot3=-0{,}6$

Смещение: $b_{вых}=0{,}2$

2. Прямой проход

$S_1=x_1\cdot w_{11}+x_2\cdot w_{21}+x_3\cdot w_{31}+b_1=0{,}2$

$a_1=\sigma(S_1)=\frac{1}{1+e^{-0{,}2}}\approx0{,}5634$

$S_2=x_1 w_{12}+x_2 w_{22}+x_3 w_{32}+b_2=0{,}2563$

$a_2=\sigma(S_2)=\frac{1}{1+e^{-0{,}255}}\approx0{,}5634$

Выходной слой: $y=a_1\cdot w_{вых1}+a_2 w_{вых2}+b_{вых}=0{,}13$

Ошибка MSE: $E=\frac{1}{2}(y-d)^2\approx0{,}1012$

3. Обратный проход

Ошибка выходного слоя: $\delta_{вых}=y-d=-0{,}4637$

Градиенты выходного слоя: $\frac{\partial E}{\partial w_{вых1}}=\delta_{вых}\cdot a_1=-0{,}35$

$\delta_{вых}\cdot a_2=-0{,}26$

$\delta_{вых}=-0{,}4637$

Ошибки скрытого слоя: $\delta_1=\delta_{вых}\cdot w_{вых1}\cdot a_1(1-a$

$=-0{,}0573$; $\delta_2=0{,}0684$

Градиенты скрытого слоя: $\frac{\partial E}{\partial w_{21}}=\delta_1 x_1=-0{,}$

$\frac{\partial E}{\partial w_{21}}=\delta_2 x_2=-0{,}$

и т.д.

4. Обновление весов (при $\eta=0{,}1$): $w_{нов}=w_{ст}-$

Выходной слой: $w_{вых1}^{нов}=0{,}5255$, $w_{вых2}^{нов}=-0{,}5739$, $b_{вых}^{нов}$

Скрытый слой: $w_{11}^{нов}=0{,}1315$, $w_{21}^{нов}=0{,}30287$,

$w_{31}^{нов}=-0{,}0954$, $b_1^{нов}=0{,}10573$ и т.д.

Вывод :

1. Влияние размера окна p на качество прогноза

- Слишком маленькое окно (p=2p=2): Не позволяет сети точно спрогнозировать ряд, так как исследуемый ряд представляет собой сумму двух гармоник с разной частотой (ω1=0.4ω1=0.4, ω2=0.9ω2=0.9). Для однозначного определения состояния системы из двух гармоник (частот и фаз) математически требуется знать минимум 4 предыдущие точки. Окна p=2p=2 недостаточно для идентификации локальной динамики.
- При каком p ошибка перестает уменьшаться: Ошибка существенно падает при p≥4…6p≥4…6. Начиная с p=6p=6 (параметр Варианта 3), дальнейшее увеличение окна (p=12p=12) не дает ощутимого прироста точности, но увеличивает количество весовых коэффициентов и замедляет обучение.
- Почему слишком большое окно не дает выигрыша: Избыточный размер окна приводит к усложнению архитектуры (росту числа входов), расширению области поиска глобального минимума и риску избыточного запоминания шума/деталей вместо выделения фундаментальной гармонической структуры.

2. Влияние числа скрытых нейронов N на точность и скорость обучения

- Влияние N: С увеличением N повышается аппроксимационная способность сети и скорость снижения ошибки на обучающем участке (требуется меньше эпох).
- Достаточность минимального N: Минимального числа нейронов недостаточно для точного воспроизведения нелинейной суммы двух гармоник — сеть не может сформировать необходимый разделяющий гиперрельеф. Значение N=5 является оптимальным.
- Переобучение: При слишком большом N (N≥10) наблюдается эффект переобучения: ошибка на обучении стремится к нулю, однако ошибка на тесте (MAE) начинает расти из-за подгонки весов под конкретные значения обучающего отрезка.

3. Функция активации выходного слоя и обучении на ненормализованных данных

- Почему линейная функция на выходе (f(s)=s): Задача прогнозирования временного ряда является задачей регрессии. Выходное значение x(k) является непрерывной величиной, которая не ограничена рамками [0;1]. Линейная функция позволяет сети выдавать любые вещественные значения.

- **Что было бы при сигмоиде на выходе:** Сигмоида жестко ограничила бы выход сети интервалом (0;1). Модель в принципе не смогла бы предсказать значения ряда, выходящие за эти пределы (или денормализованные значения вне диапозона).
- **Что произошло бы при обучении на ненормализованных данных:** Ненормализованные входы в диапазоне [−2.3;+2.3] привели бы к "насыщению" сигмоидальных нейронов скрытого слоя (значения |s| были бы слишком велики). В результатах производная сигмоиды σ′(s)≈0, градиенты "занулились" бы (проблема затухания градиента), и сеть прекратила бы обучаться.

4. Правила нормализации данных

- **Почему нормализация только по обучающему участку:** Использование xmin*xmin* и xmax*xmax* со всего ряда (включая тест) является "утечкой данных из будущего" (Data Leakage). На практике тестовый участок в момент обучения неизвестен.
- **Выход тестовых значений за диапазон [0;1]:** Если на тестовом участке ряд принимает значения больше xmaxtrain*n* или меньше xmintrain их нормализованные значения выходят за границы [0;1][0;1]. Благодаря линейному выходному слою сеть способна экстраполировать значения за пределы [0;1][0;1], однако если отклонение значительно, точность прогноза на таких участках снижается. На наших данных диапазон тестовых значений практически совпал с обучающим, поэтому снижения точности не произошло.

5. Устойчивость обучения к случайной инициализации весов

- Случайная инициализация весов задает начальную точку на поверхности функции потерь.
- Серии из 5 запусков показывают разброс по числу эпох (от ~90 до ~250 эпох). При неблагоприятной начальной инициализации веса могут попасть в "плоское" плато функции потерь.
- Запуски могут не достигнуть Ee≤10−44 за 20 000 эпох, если:
    1. Скорость обучения η слишком мала (медленная сходимость) или слишком велика (колебания вокруг минимума);
    2. Число нейронов N или размер окна p заданы слишком малыми для описания сложности ряда.

6. Ошибка рекурсивного многошагового прогноза

- Рост ошибки: При рекурсивном прогнозе на шаге t+1*t*+1 в качестве входов используются не истинные значения ряда, а собственное предсказание сети x^(t), полученное на предыдущем шаге.

- Накопление ошибки: Ошибка каждого предыдущего шага подставляется на вход модели и мультипликативно накапливается (происходит дрейф фазы и амплитуды).
- Сравнение: Одношаговый прогноз всегда существенно точнее многошагового, так как оперативно "корректируется" реальными значениями ряда.
- Пригодность прогноза: Прогноз можно считать пригодным до тех пор, пока относительная ошибка не превышает 5% от размаха ряда. Для исследуемого ряда рекурсивный прогноз остается пригодным на 5–7 шагов вперед, после чего накапливается фазовый сдвиг.

7. Обобщающая способность и способы ее улучшения

- Различие ошибок на Train и Test: Небольшая разница между ошибками на обучении и тесте указывает на хорошую обобщающую способность (сеть выучила закономерность, а не запомнила точки).
- Меры по улучшению обобщения:
    1. Ранняя остановка (Early Stopping): Прекращение обучения, как только ошибка на валидационном множестве начинает расти.
    2. Уменьшение N*N*: Сокращение избыточной емкости сети (регуляризация архитектуры).
    3. Добавление шума: Зашумление обучающих данных не дает сети точно "зазубрить" координаты точек, заставляя ее сглаживать восстанавливаемую функцию.
    4. Увеличение обучающей выборки: Чем больше периодов гармоники видит сеть, тем точнее она определяет параметры частот.
- Эксперимент с шумом: Добавление небольшого гауссовского шума к обучающему ряду незначительно увеличивает ошибку на обучении, но делает рекурсивный прогноз более устойчивым на длинных горизонтах.