

Министерство образования Республики Беларусь

Учреждение образования

«Брестский государственный технический университет»

Кафедра интеллектуальных информационных технологий

Лабораторная работа №3

**по дисциплине «Модели решения задач в интеллектуальных
системах»**

За седьмой семестр

Тема:

**«Многослойный персептрон для XOR с ReLU на скрытых
слоях: сравнение активационных функций»**

Выполнил:

студент 4 курса
группы ИИ-26
Ковальчук А.И.

Проверил:

НИКИТИН С. К.

Брест 2026

Цель работы

На основе многослойного персептрона архитектуры 2-2-1 из лабораторной работы №2 исследовать влияние активационной функции ReLU (Rectified Linear Unit) на скрытых слоях. Провести сравнительный анализ обучения сети с функцией активации сигмоида (базовая конфигурация) и ReLU (новая конфигурация) по скорости сходимости, качеству обучения, форме разделяющей поверхности и устойчивости к инициализации весов.

2. Постановка задачи

За основу взят код многослойного персептрона 2-2-1 с функцией потерь бинарной кросс-энтропии (BCE) из ЛР №2. На скрытом слое реализована активация ReLU и соответствующее обратное распространение ошибки; на выходном слое сохранена сигмоида. Сеть обучается на полной таблице истинности XOR в двух конфигурациях.

Конфигурация А (базовая): MLP 2-2-1, сигмоида на всех слоях, BCE, нормализованные целевые значения 0/1.

Конфигурация В (новая): MLP 2-2-1, ReLU на скрытом слое, сигмоида на выходном, BCE, метки 0/1.

Критерий остановки для обеих конфигураций — как в ЛР №2: суммарная (средняя по выборке) ошибка $E_s \leq E_e$ либо достижение максимума эпох. Для каждой конфигурации фиксируются число эпох до останова, итоговые E_s и ассурасу, средняя абсолютная ошибка MAE в исходной шкале $[c_0; c_1]$. Проводится не менее пяти запусков с разными seed. Строятся график сходимости $E_s(t)$, диаграмма разброса числа эпох и тепловые карты выхода сети на плоскости $(A, B) \in [-10; 10]^2$. Реализуется режим функционирования: по паре (A, B) сеть выдаёт выход в нормализованной шкале, в исходной шкале и метку класса.

3. Данные варианта

Вариант совпадает с лабораторной работой №2: $c_0 = -4$, $c_1 = -9$. Входы и целевой XOR задаются в этой шкале, затем линейно нормализуются в $[0; 1]$:

$$x' = (x - c_0) / (c_1 - c_0), \quad y' \in \{0, 1\}.$$

Обратное преобразование выхода сети $\hat{y} \in (0; 1)$ в исходную шкалу:

$$y_{real} = c_0 + \hat{y} \cdot (c_1 - c_0).$$

Класс выбирается по ближайшему из $\{c_0, c_1\}$. Таблица истинности XOR для варианта 7 приведена ниже.

A	B	XOR в шкале $[c_0; c_1]$	Метка 0/1
-4	-4	-4 (c_0)	0
-4	-9	-9 (c_1)	1
-9	-4	-9 (c_1)	1
-9	-9	-4 (c_0)	0

Таблица 1 — Обучающая выборка (полная таблица истинности XOR)

Одинаковые входы (оба c_0 или оба c_1) соответствуют классу c_0 , различные — классу c_1 . В нормализованных координатах это классический XOR: $(0,0) \rightarrow 0$, $(0,1) \rightarrow 1$, $(1,0) \rightarrow 1$, $(1,1) \rightarrow 0$. Задача линейно неразделима, поэтому однослойный персептрон её не решает; необходима скрытая нелинейность, которую и даёт архитектура 2-2-1.

4. Теоретические сведения

4.1. Архитектура 2-2-1

Многослойный персептрон состоит из двух входов, скрытого слоя из двух нейронов и одного выходного нейрона. Для i -го нейрона слоя

$$z = w^T x + b, \quad a = f(z),$$

где f — функция активации. Скрытый слой формирует два нелинейных признака; выходной нейрон строит из них разделяющую поверхность. Без

скрытого слоя XOR не реализуется ни сигмодой, ни ReLU: один нейрон задаёт не более одной линейной (или кусочно-линейной с одним изломом) границы.

4.2. Сигмоида

$$\sigma(z) = 1 / (1 + e^{(-z)}), \quad \sigma'(z) = \sigma(z) \cdot (1 - \sigma(z)).$$

Сигмоида гладкая, ограничена интервалом (0; 1) и удобна на выходе бинарного классификатора. Недостаток — насыщение при больших $|z|$: производная стремится к нулю (затухание градиента). В мелкой сети 2-2-1 это замедляет обучение, но редко полностью останавливает его: градиент остаётся ненулевым на всех примерах.

4.3. ReLU

$$\text{ReLU}(z) = \max(0, z), \quad \text{ReLU}'(z) = I[z > 0].$$

В положительной полуоси ReLU линейна, поэтому градиент не затухает из-за насыщения. Вычисление дешёвое, активации разреженные. Обратная сторона — «мёртвые» нейроны: если $z \leq 0$ на всех объектах, производная равна нулю, и веса этого нейрона больше не обновляются. Для входа (0, 0) при нулевом смещении $z = 0$, и при строгом правиле $z > 0$ скрытый слой не получает градиента с этого примера. Поэтому веса инициализируются малыми случайными значениями, а для ReLU смещение берётся небольшим положительным.

4.4. Функция потерь и обучение

Используется бинарная кросс-энтропия по четырём примерам таблицы истинности:

$$E_s = -(1/N) \sum [y \log \hat{y} + (1 - y) \log(1 - \hat{y})], \quad N = 4.$$

Обучение — метод обратного распространения ошибки в онлайн-режиме (batch size = 1). Для выходного нейрона с сигмодой и BCE локальная ошибка пропорциональна $(\hat{y} - y)$. Для скрытого ReLU-нейрона

дельта умножается на индикатор $1[z > 0]$ и передаётся на веса через обычное правило цепочки. Критерий останова: $E_s \leq E_e = 0,01$ либо 1500 эпох.

5. Описание реализации

Реализация выполнена на NumPy без библиотек автоматического дифференцирования (PyTorch, TensorFlow, scikit-learn не использовались). Графики построены в Matplotlib. Основные элементы:

- DenseLayer — полносвязный слой с активациями sigmoid и ReLU; forward сохраняет предыктивацию z , derivative возвращает $\sigma(1-\sigma)$ либо $1[z > 0]$.
- Sequential.fit — онлайн-SGD: случайная перестановка четырёх примеров на каждой эпохе, обновление весов после каждого объекта, клип градиента по модулю 5.
- Инициализация: веса $w \sim U(-0,5; 0,5)$ (малые случайные значения по требованию работы). Для ReLU смещение $b \sim U(0,05; 0,25)$, для сигмоиды $b = 0$. Веса задаются при сборке модели, до перемешивания выборки, чтобы seed однозначно определял старт.
- Нормализация входов/меток, пересчёт $\hat{y}$ в $[c_0; c_1]$, accuracy по ближайшему из $\{c_0, c_1\}$, MAE в исходной шкале.

Параметры эксперимента одинаковы для обеих конфигураций: $\alpha = 0,5$, $\text{batch size} = 1$, $\text{max_epochs} = 1500$, $E_e = 0,01$, $\text{seed} \in \{42, 7, 13, 21, 99\}$.

Параметр	Конфигурация А	Конфигурация В
Архитектура	2-2-1	2-2-1
Скрытый слой	сигмоида	ReLU
Выходной слой	сигмоида	сигмоида
Потери	BCE	BCE
Целевые значения	0 / 1	0 / 1
Режим обучения	онлайн (bs = 1)	онлайн (bs = 1)
α	0,5	0,5
E_e	0,01	0,01

Максимум эпох	1500	1500
---------------	------	------

Таблица 2 — Сравниваемые конфигурации

6. Результаты эксперимента

6.1. Серия запусков: конфигурация А (сигмоида)

Все пять запусков достигли критерия $E_s \leq 0,01$. Аккуратность на таблице истинности равна 1,00, MAE в шкале $[c_0; c_1]$ составляет около 0,05 (порядка 1 % длины интервала $|c_1 - c_0| = 5$).

seed	Эпохи	Сходимость	E_s	Accuracy	MAE $[c_0; c_1]$
42	934	да	0,009998	1,00	0,0497
7	959	да	0,009986	1,00	0,0497
13	1118	да	0,009991	1,00	0,0497
21	779	да	0,009990	1,00	0,0497
99	864	да	0,009983	1,00	0,0497

Таблица 3 — Пять запусков конфигурации А

Статистика по эпохам успешных запусков: $\min = 779$, $\max = 1118$, $\text{mean} = 930,8$, $\text{std} = 112,6$. Разброс умеренный: сигмоида стабильно решает XOR при разных начальных весах, но сходится относительно медленно из-за насыщения и малых градиентов на ранних эпохах.

6.2. Серия запусков: конфигурация В (ReLU)

ReLU даёт качественно иную картину: при удачной инициализации критерий достигается за 118–133 эпохи (примерно в 7 раз быстрее сигмоиды), но два запуска из пяти не сошлись за 1500 эпох и остались с accuracy 0,75.

seed	Эпохи	Сходимость	E_s	Accuracy	MAE $[c_0; c_1]$
42	118	да	0,009839	1,00	0,0489
7	126	да	0,009918	1,00	0,0493
13	1500	нет	0,347119	0,75	1,2502

21	1500	нет	0,477479	0,75	1,6582
99	133	да	0,009820	1,00	0,0488

Таблица 4 — Пять запусков конфигурации В

По трём успешным запускам: $\min = 118$, $\max = 133$, $\text{mean} = 125,7$, $\text{std} = 6,1$. Среди сошедшихся траекторий ReLU даже устойчивее по числу эпох (std 6 против 113 у сигмоиды), однако сама вероятность попасть в «хороший» бассейн притяжения ниже: 3/5 против 5/5. Неуспешные запуски застревают в типичном локальном минимуме XOR, когда сеть ведёт себя как линейный классификатор (OR/AND-подобное правило) и верно восстанавливает только три из четырёх точек. На $\text{seed} = 21$ после обучения один скрытый нейрон остаётся тождественно нулевым — классический мёртвый ReLU; эффективная архитектура деградирует до 2-1-1 и XOR уже не представим.

6.3. График сходимости

На рисунке 1 совмещены кривые $E_s(t)$ представительных запусков ($\text{seed} = 42$, оба сошлись). Сигмоида долго держит $E_s \approx \ln 2 \approx 0,69$ (выход около 0,5), затем плавно снижается и достигает E_e только к 934-й эпохе. ReLU после короткого плато резко падает и пересекает E_e уже на 118-й эпохе. Это согласуется с тем, что в активной области градиент ReLU не подавляется насыщением.




Рисунок 1 — Сходимость Es от номера эпохи (представительные запуски, $seed = 42$)

6.4. Разброс числа эпох

Рисунок 2 показывает число эпох по пяти $seed$. Для сигмоиды все столбики соответствуют успешной сходимости в диапазоне 779–1118. Для ReLU три коротких столбика (118, 126, 133) — успешные запуски, два заштрихованных столбика высоты 1500 — случаи, когда Ee не достигнут. Визуально подтверждается вывод: ReLU быстрее, но менее надёжна к инициализации.




Рисунок 2 — Диаграмма разброса числа эпох по пяти запускам

6.5. Разделяющая поверхность

Для тех же представительных сетей построена карта выхода $\hat{y}$ на $(A, B) \in [-10; 10]^2$ с наложением четырёх обучающих точек (рисунок 3). Обе сети на этих точках дают accuracy 1 и $MAE \approx 0,05$, то есть XOR на таблице истинности решён.




Рисунок 3 — Тепловые карты $\hat{y}(A, B)$, MAE и ассигасу представительных сетей A и B

Конфигурация A (сигмоида). Границы гладкие, с широкой переходной полосой. Красная область (класс c_1) образует «ленту», проходящую через точки $(-4, -9)$ и $(-9, -4)$; остальная плоскость в основном синяя. Четыре обучающие точки классифицируются верно, но вне их окрестности поверхность не воспроизводит XOR глобально: например, точка $(-10, 10)$ получает $\hat{y} \approx 0$ и класс c_0 , хотя входы сильно различны.

Конфигурация B (ReLU). Поверхность кусочно-линейная: широкая синяя диагональная полоса вдоль $A \approx B$ (одинаковые входы $\rightarrow$ класс c_0) и красные полуплоскости вне неё (различные входы $\rightarrow$ класс c_1). Изломы соответствуют линиям $z = 0$ скрытых ReLU-нейронов; после выходной

сигмоиды остаётся узкая, но всё ещё более «угловатая», чем у конфигурации А, переходная зона. Ожидаемые кусочно-линейные границы наблюдаются. Такая геометрия ближе к идеальному XOR на всей плоскости: диагональ равных координат — класс c_0 , вне диагонали — класс c_1 .

Выходы представительных сетей на таблице истинности:

A	B	y	$\hat{y}_A$	yA_real	$\hat{y}_B$	yB_real
-4	-4	-4	0,0078	-4,0391	0,0161	-4,0805
-4	-9	-9	0,9911	-8,9554	0,9966	-8,9829
-9	-4	-9	0,9911	-8,9554	0,9965	-8,9826
-9	-9	-4	0,0141	-4,0706	0,0161	-4,0805

Таблица 5 — Выходы представительных сетей на обучающей выборке

6.6. Режим функционирования

Пользователь задаёт пару (A, B) из $[-10; 10]$. Сеть (после нормализации входа) выводит: нормализованный выход $\hat{y}$, значение в исходной шкале y_real и класс $\text{nearest}\{c_0, c_1\}$. Ниже — демонстрация на четырёх обучающих примерах и трёх дополнительных парах, а также интерактивный запрос (-7, -8) для конфигурации B.

(A, B)	Истина	$\hat{y}_A$ / yA_real / класс A	$\hat{y}_B$ / yB_real / класс B
(-4, -4)	-4	0,0078 / -4,039 / -4	0,0161 / -4,081 / -4
(-4, -9)	-9	0,9911 / -8,955 / -9	0,9966 / -8,983 / -9
(-9, -4)	-9	0,9911 / -8,955 / -9	0,9965 / -8,983 / -9
(-9, -9)	-4	0,0141 / -4,071 / -4	0,0161 / -4,081 / -4
(0, 0)	—	0,0045 / -4,023 / -4	0,0161 / -4,081 / -4
(-10, 10)	—	0,0045 / -4,023 / -4	1,0000 / -9,000 / -9
(-6,5, -6,5)	—	0,9911 / -8,955 / -9	0,0161 / -4,081 / -4
(-7, -8)*	—	—	0,1022 / -4,511 / -4

Таблица 6 — Режим функционирования. *Интерактивный ввод для сети B

На обучающих четырёх точках обе конфигурации восстанавливают класс без ошибок. Дополнительные пары выявляют различие обобщения. Точка $(-6,5, -6,5)$ лежит на диагонали между двумя объектами класса c_0 ; ReLU относит её к c_0 (как XOR «равные входы»), сигмоида — к c_1 , потому что её красная «лента» пересекает середину отрезка между обучающими c_0 . Точка $(-10, 10)$ — далёкая пара различных значений: ReLU уверенно выдаёт класс c_1 , сигмоида — c_0 . Пара $(-7, -8)$ близка по компонентам, ReLU даёт класс c_0 , что согласуется с диагональной полосой на тепловой карте.

6.7. Сводная таблица сравнения

Показатель	А (сигмоида)	В (ReLU)
Доля сходимости $E_s \leq E_e$	5 / 5	3 / 5
Эпохи (успешные): min / max	779 / 1118	118 / 133
Эпохи (успешные): mean $\pm$ std	930,8 $\pm$ 112,6	125,7 $\pm$ 6,1
Ассигасу (все 5 запусков)	1,00 / 1,00 / 1,00 / 1,00 / 1,00	1,00 / 1,00 / 0,75 / 0,75 / 1,00
Средняя ассигасу по 5 запускам	1,00	0,90
MAE успешных запусков	0,0497	0,0488 ... 0,0493
Средняя MAE по 5 запускам	0,0497	0,6111
MAE представительного seed=42	0,0497	0,0489
Мёртвые нейроны	нет	да (seed = 21)
Форма границы	гладкая	кусочно-линейная

Таблица 7 — Сравнение конфигураций по пяти запускам и MAE

Средняя MAE конфигурации В по всем пяти seed завышена неуспешными запусками (1,25 и 1,66). Если учитывать только сошедшиеся сети, MAE обеих конфигураций практически совпадают ($\sim 0,049$). То есть при успешном обучении качество восстановления шкалы $[c_0; c_1]$ у ReLU не хуже, чем у сигмoиды; различие — в скорости и в риске срыва оптимизации.

7. Ответы на контрольные вопросы

1. Какая из активационных функций обеспечила более быструю сходимость? Более устойчива?

По скорости среди успешных запусков однозначно быстрее ReLU: среднее 126 эпох против 931 у сигмоиды (выигрыш около 7,4 раза на seed = 42: 118 против 934). По устойчивости к инициализации устойчивее сигмоида: 5/5 сходимостей против 3/5. У ReLU условная устойчивость внутри успешных запусков даже выше (std эпох 6 против 113), но два старта попадают в локальный минимум или в режим мёртвого нейрона. Итог: ReLU быстрее, сигмоида надёжнее.

2. Как отличается форма разделяющей поверхности? Наблюдаются ли кусочно-линейные границы для ReLU?

У сигмоиды поверхность гладкая, с сигмоидальным переходом и локальной «лентой» класса c_1 около обучающих точек разных входов. У ReLU граница составлена из линейных участков, порождённых линиями переключения скрытых нейронов $z = 0$; на тепловой карте это диагональная полоса класса c_0 и прямолинейные кромки красных областей. Да, ожидаемые кусочно-линейные границы наблюдаются. Выходная сигмоида лишь сглаживает сам переход $\hat{y}$ через 0,5, но геометрия областей остаётся полигональной.

3. Почему ReLU часто предпочитают сигмоиде в глубоких сетях? Подтверждается ли это на XOR?

В глубоких сетях сигмоида на многих слоях почти наверняка насыщается, градиент экспоненциально затухает, обучение нижних слоёв останавливается. ReLU в активной области имеет производную 1, не сжимает градиент, считается за $O(1)$ и индуцирует разреженность. На мелком XOR это подтверждается только частично. Положительная сторона — резкое ускорение сходимости, когда оба скрытых нейрона живы. Отрицательная — мёртвые нейроны и схлопывание двух признаков в один, чего в глубоких сетях с большим числом каналов обычно компенсируют избыточностью и

трюками инициализации (He, ненулевой bias). Сеть 2-2-1 слишком узкая, чтобы прощать смерть даже одного нейрона, поэтому «предпочтение ReLU» на XOR нельзя считать безусловным: выигрыш в скорости есть, выигрыша в надёжности нет.

4. Изменилась ли способность сети решать XOR при переходе на ReLU?

Представимость XOR не исчезла: и сигмоида, и ReLU в архитектуре 2-2-1 XOR реализуют (успешные запуски В дают $\hat{y} \approx (0,016, 0,997, 0,997, 0,016)$ и accuracy 1). Способность решать задачу обеспечивается скрытым слоем из двух нелинейных нейронов, а не конкретной формой f . Однако оптимизация для ReLU хрупче: при мёртвом нейроне ёмкость падает до одного скрытого признака, и XOR перестаёт быть достижимым уже не из-за активации как функции, а из-за фактической потери архитектуры. Оба варианта успешно справляются, когда скрытые нейроны остаются функциональными; гарантии сходимости у ReLU на пяти случайных seed нет.

5. Есть ли случаи «мёртвых нейронов» при ReLU? Как это повлияло на обучение?

Да. На seed = 21 после 1500 эпох один скрытый нейрон выдаёт 0 на всех четырёх примерах таблицы истинности. Сеть вырождается в 2-1-1, Es застревает около 0,48, accuracy = 0,75, MAE = 1,66. На seed = 13 нейроны не полностью мертвы, но выучивают почти один и тот же линейный признак (схлопывание), что даёт тот же локальный минимум accuracy 0,75 при Es $\approx$ 0,35. В успешных запусках (42, 7, 99) оба нейрона живы, и XOR собирается. Вывод: мёртвый ReLU на ширине 2 критичен — теряется ровно тот второй признак, который отличает XOR от линейно разделимой задачи.

6. Как выбор активации соотносится с необходимостью многослойной архитектуры для XOR?

XOR линейно неразделим. Ни сигмоида, ни ReLU на одном нейроне (2-1) задачу не решают: это по-прежнему одна гиперплоскость (у ReLU — плюс

обнуление полупространства, что XOR не добавляет). Нужен скрытый слой, дающий хотя бы два различных нелинейных признака (например, «А и не В» и «В и не А», либо «OR» и «AND»). Выбор f меняет форму этих признаков и лёгкость их выучивания, но не отменяет многослойность. Более того, ReLU делает многослойность ещё более обязательной в практическом смысле: если один из двух скрытых нейронов умирает, сеть снова становится фактически однослойной и XOR теряется.

7. Что показывает визуализация разделяющей поверхности? Совпадает ли граница с ожидаемой для XOR?

Ожидаемая геометрия XOR в координатах варианта: класс c_0 на диагонали равных входов (оба c_0 или оба c_1 и все промежуточные $A \approx B$) и класс c_1 вне диагонали. Конфигурация В это воспроизводит: синяя полоса вдоль $A \approx B$, красные области при сильно различных A и B ; четыре обучающие точки лежат в правильных зонах. Конфигурация А верно разделяет те же четыре точки, но глобальная карта ближе к локальной интерполяции: красная полоса соединяет две точки класса c_1 и пересекает диагональ, из-за чего середина $(-6,5, -6,5)$ ошибочно становится c_1 , а далёкая пара $(-10, 10)$ — c_0 . Таким образом, на обучающей выборке граница обеих сетей совпадает с XOR; на плоскости $[-10; 10]^2$ ожидаемой XOR-геометрии существенно ближе ReLU.