

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа № 3

По дисциплине « Модели решения задач в интеллектуальных системах»

Тема: «Многослойный персептрон для XOR с ReLU на скрытых слоях: сравнение активационных функций»

Выполнил:
Студент 4 курса
Группы ИИ-26
Рудь В.В.
Проверил:
Никитин С.К.

Вариант 15

Цель: На основе многослойного персептрона архитектуры 2-2-1 из ЛР №2, исследовать влияние активационной функции ReLU (Rectified Linear Unit) на скрытых слоях. Провести сравнительный анализ обучения сети с функцией активации Сигмоида (базовая конфигурация) и ReLU (новая конфигурация) по скорости сходимости, качеству обучения, форме разделяющей поверхности и устойчивости к инициализации весов.

Задачи лабораторной работы

1. Взять за основу код многослойного персептрона 2-2-1 с функцией потерь BCE из ЛР №2.
2. Реализовать активационную функцию ReLU на скрытом слое и осуществить корректное обратное распространение ошибки для ReLU. На выходном слое оставить Сигмоиду.
3. Обучить сеть на полной таблице истинности в двух конфигурациях:
 - Конфигурация А (базовая): MLP 2-2-1, Сигмоида на всех слоях, BCE, нормализованные целевые значения (0/1);
 - Конфигурация В (новая): MLP 2-2-1, ReLU на скрытом слое, Сигмоида на выходном, BCE, нормализованные (0/1).
4. Критерий остановки для обеих конфигураций: суммарная ошибка $E_s \leq E_e$ (как в ЛР №2).
5. Для каждой конфигурации зафиксировать:
 - Количество эпох до критерия остановки.
 - Итоговую суммарную ошибку и ассурасу.
 - Среднюю абсолютную ошибку в исходной шкале $[c_0; c_1]$.
6. Провести не менее 5 запусков обучения для каждой конфигурации с разными seed и сравнить устойчивость.
7. Построить графики:
 - График сходимости (суммарная ошибка E_s от эпохи) для обеих конфигураций на одних осях.
 - Диаграмма разброса числа эпох по 5 запускам (столбики) для конфигурации А и В.
8. Визуализация разделяющей поверхности:

- Для представительного экземпляра каждой конфигурации построить карту (heatmap) выходного значения сети на плоскости $(A, B) \in [-10; 10]^2$ с наложением 4 точек обучающей выборки.
- Описать, как ReLU изменяет форму разделяющей поверхности (кусочно-линейные границы vs гладкие).

9. Реализовать режим функционирования сети:

- Пользователь вводит (A, B) из $[-10; 10]$.
- Сеть выводит: выход в нормализованной шкале, выход в исходной шкале $[c_0; c_1]$, класс.
- Продемонстрировать на 4 обучающих примерах + 2–3 дополнительных парах.


10. Создать таблицу сравнения (статистика по 5 запускам, MAE для обеих конфигураций).





11. Вывод: ответить на все вопросы и провести анализ результатов.

Вариант 15 ($c_0 = 6, c_1 = -4$)

A	B	$A \oplus B$
6	6	6
6	-4	-4
-4	6	-4
-4	-4	6

Результат:









Таблица сравнения (5 запусков)

Config	Seed	Reached	Epochs	Es_final	Accuracy	MAE	Dead
A	1	True	9420	0.010000	1.000	0.0250	0
A	2	True	9430	0.009999	1.000	0.0250	0
A	3	True	9550	0.010000	1.000	0.0250	0
A	4	False	20000	2.015277	0.750	3.2796	0
A	5	False	20000	1.978974	0.750	3.2975	0
B	1	False	20000	1.943378	0.750	3.3331	0
B	2	False	20000	1.943378	0.750	3.3331	0
B	3	True	1085	0.009994	1.000	0.0249	0
B	4	False	20000	1.411780	0.750	2.5000	0
B	5	True	1084	0.009998	1.000	0.0249	0

A (Sigmoid): mean epochs=13680.0±5160.5, mean MAE=1.3304, mean accuracy=0.900, dead neurons total=0

B (ReLU): mean epochs=12433.8±9266.7, mean MAE=1.8432, mean accuracy=0.850, dead neurons total=0

Представители: A seed=1, B seed=3

Демонстрация на обучающих примерах и дополнительных парах:

Вход (A, B) = (6.0, 6.0)

A (Sigmoid): output_norm=0.997841, output_res=5.9784, class=6.0

B (ReLU): output_norm=0.999849, output_res=5.9985, class=6.0

Вход (A, B) = (6.0, -4.0)

A (Sigmoid): output_norm=0.002210, output_res=-3.9779, class=-4.0

B (ReLU): output_norm=0.004845, output_res=-3.9516, class=-4.0

Вход (A, B) = (-4.0, 6.0)

A (Sigmoid): output_norm=0.003338, output_res=-3.9666, class=-4.0

B (ReLU): output_norm=0.004845, output_res=-3.9516, class=-4.0

Вход (A, B) = (-4.0, -4.0)

A (Sigmoid): output_norm=0.997723, output_res=5.9772, class=6.0

B (ReLU): output_norm=0.999877, output_res=5.9988, class=6.0

Вход (A, B) = (0, 0)

A (Sigmoid): output_norm=0.997776, output_res=5.9778, class=6.0

B (ReLU): output_norm=0.006840, output_res=-3.9316, class=-4.0

Вход (A, B) = (3, -7)

A (Sigmoid): output_norm=0.002208, output_res=-3.9779, class=-4.0

B (ReLU): output_norm=0.849629, output_res=4.4963, class=6.0

Вход (A, B) = (5, 2)

A (Sigmoid): output_norm=0.978461, output_res=5.7846, class=6.0

B (ReLU): output_norm=0.849510, output_res=4.4951, class=6.0

Вывод:

1. Какая из активационных функций (Сигмоида или ReLU) обеспечила более быструю сходимость? Более устойчива?

Более быструю сходимость обеспечила ReLU. В удачных запусках (seed=3 и seed=5) сеть с ReLU достигла критерия остановки всего за **~1085 эпох**, тогда как Сигмоида в своих лучших запусках (seed=1,2,3) сходилась за **~9400–9550 эпох**. Разница в скорости — почти в 9 раз.

Более устойчивой оказалась Сигмоида. Она успешно сошлась в 3 из 5 запусков, тогда как ReLU — только в 2 из 5. Два запуска Сигмоиды и три запуска ReLU застряли на 20000 эпохах, так и не достигнув целевой ошибки (Accuracy = 0.75). Это говорит о том, что в такой крошечной архитектуре (2-2-1) ReLU более

чувствительна к начальной инициализации весов и чаще попадает в локальные минимумы.

2. Как отличается форма разделяющей поверхности между конфигурациями А и В? Наблюдаются ли ожидаемые кусочно-линейные границы для ReLU?

Да, различия хорошо видны на heatmap.

- **Конфигурация А (Сигмоида):** Разделяющая поверхность гладкая. Переход от одного класса к другому (от синего к красному) происходит плавно, с широкой градиентной зоной.
- **Конфигурация В (ReLU):** Граница кусочно-линейная. Видны четкие прямые линии изломов и резкие переходы. Это полностью соответствует теоретическим ожиданиям: ReLU состоит из линейных участков, поэтому итоговая поверхность имеет ломаную форму.

3. Почему ReLU часто предпочитают Сигмоиде в глубоких сетях?

Подтверждается ли это на XOR?

ReLU предпочитают из-за отсутствия проблемы затухающих градиентов (её производная равна 1 для положительных входов, тогда как у Сигмоиды она стремится к 0 на краях) и более высокой вычислительной скорости.

На XOR это подтверждается частично: там, где ReLU стартовала удачно, она действительно обучалась в разы быстрее. Однако на такой малой сети (2-2-1) преимущество в скорости нивелируется высокой чувствительностью к инициализации: без специальных методов (например, инициализации He) ReLU чаще застревает. В глубоких сетях эту проблему решают большим количеством нейронов и правильной инициализацией.

4. Изменилась ли способность сети решать XOR при переходе на ReLU, или оба варианта успешно справляются благодаря архитектуре?

Способность решать XOR не изменилась. Обе конфигурации в удачных запусках достигают идеальной точности (Accuracy = 1.0) и минимальной ошибки (MAE $\approx$ 0.025). Это доказывает, что ключевую роль играет именно архитектура (наличие скрытого слоя с нелинейной активацией), а не конкретный тип функции. И Сигмоида, и ReLU обеспечивают необходимую нелинейность для разделения классов.

5. Есть ли случаи "мёртвых нейронов" при ReLU (нейронов, выдающих 0)? Как это повлияло на обучение?

В данном эксперименте мёртвых нейронов не обнаружено (столбец Dead = 0 во всех запусках). Это связано с тем, что веса инициализировались малыми случайными значениями в диапазоне $[-0.5, 0.5]$, а входные данные нормализованы. Нейроны не уходили в глубокую отрицательную область, где ReLU всегда выдает 0. Поскольку мёртвых нейронов не было, это не оказало негативного влияния на

обучение, но неудачные запуски всё равно случались из-за попадания в локальные минимумы всей сети.

6. Как выбор активационной функции соотносится с необходимостью многослойной архитектуры для XOR?

XOR — классический пример **линейно неразделимой** задачи. Однослойный перцептрон не сможет её решить ни с Сигмойдой, ни с ReLU. Скрытый слой необходим, чтобы преобразовать входное пространство в новое, где классы станут линейно разделимыми. Выбор активации здесь влияет лишь на **форму** этого преобразования: Сигмоида создает гладкие искривления пространства, а ReLU — кусочно-линейные. Обе функции успешно справляются с задачей создания нелинейности, необходимой для XOR.

7. Что показывает визуализация разделяющей поверхности для обеих конфигураций? Совпадает ли граница между классами с ожидаемой для XOR?

Визуализация показывает выходное значение сети во всех точках плоскости $(A, B) \in [-10; 10]^2$.

Граница между классами (переход от -4 к 6) проходит по диагонали, разделяя точки (6,6) и (-4,-4) от (6,-4) и (-4,6). Это **полностью совпадает с ожидаемой логикой XOR**.

Для Сигмоиды граница размытая и гладкая, для ReLU — более резкая и ломаная. Но в обоих случаях сеть правильно классифицирует все 4 обучающие точки, а также корректно интерполирует значения вблизи них.