Министерство образования Республики Беларусь

Учреждение образования

«Брестский государственный технический университет»

Кафедра ИИТ

Лабораторная работа № 4

По дисциплине « Модели решения задач в интеллектуальных системах»

Тема: «Многослойный персептрон для прогнозирования временного ряда: влияние размера окна и числа скрытых нейронов»

Выполнил:

Студент 4 курса

Группы ИИ-26

Рудь В.В.

Проверил:

Никитин С.К.

Брест 2026

Вариант 15

Цель работы: на основе многослойного персептрона p–N–1 решить задачу прогнозирования временного ряда; научиться формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовать влияние размера окна p и числа нейронов скрытого слоя N на точность и скорость обучения.

Таблица вариантов

Ряд: $x(k) = a \cdot cos(b \cdot k) + c \cdot sin(d \cdot k)$,
k = 0…199, p – размер окна, N – число скрытых нейронов.

Вариант	a	b	c	d	p	N
1	1.0	0.30	0.5	0.70	6	4

Результаты:

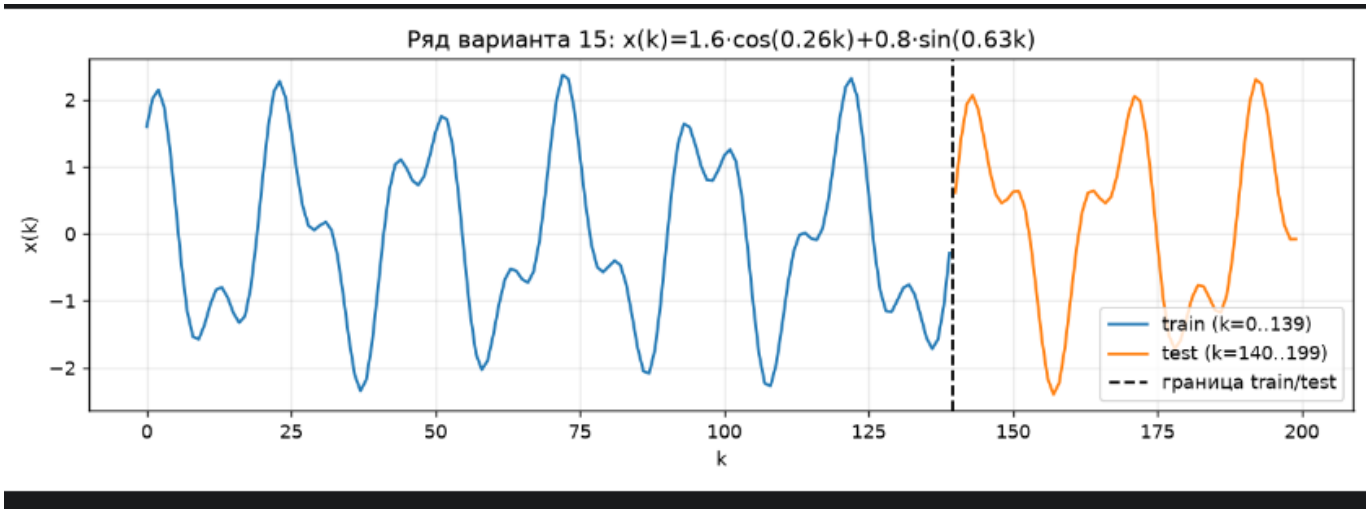


Рис. 1. Ряд варианта 15 с границей train/test. На тестовом участке видны локальные экстремумы чуть больше, чем на train: x_max(test) = 2.3054, x_max(train) = 2.3717; x_min(test) = −2.3987 < x_min(train) = −2.3444. Поэтому нормированный тест слегка выходит за [0; 1]: [−0.0115; 0.9859].

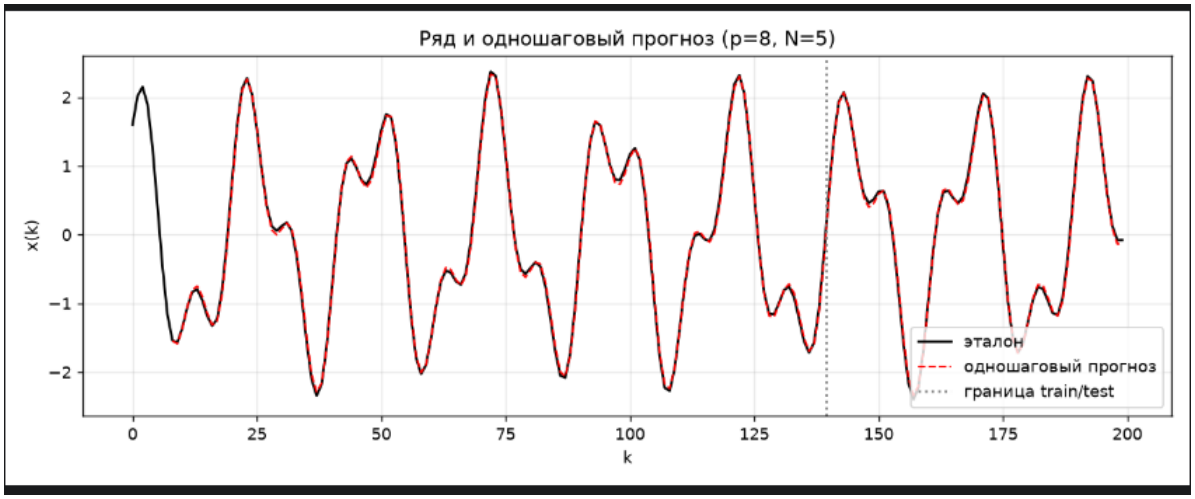


Рис. 2. Эталон и одношаговый прогноз (p = 8, N = 5). Прогноз практически накладывается на эталон на обоих участках — MAE = 0.0355.

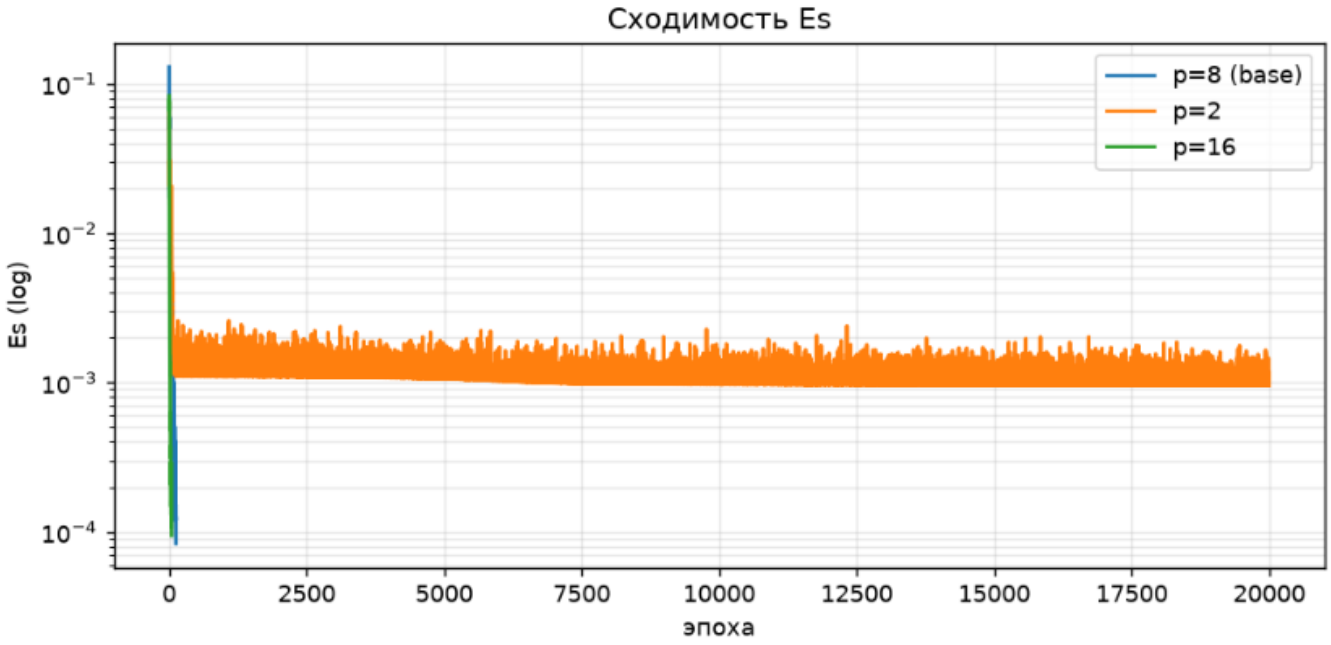


Рис. 3. Сходимость Es в логарифмической шкале для p = 8, p = 2, p = 16. Кривая p = 2 «застревает» на уровне 10^{-3} и не достигает 10^{-4} за 20000 эпох; p = 8 и p = 16 сходятся за первые ~100 эпох.

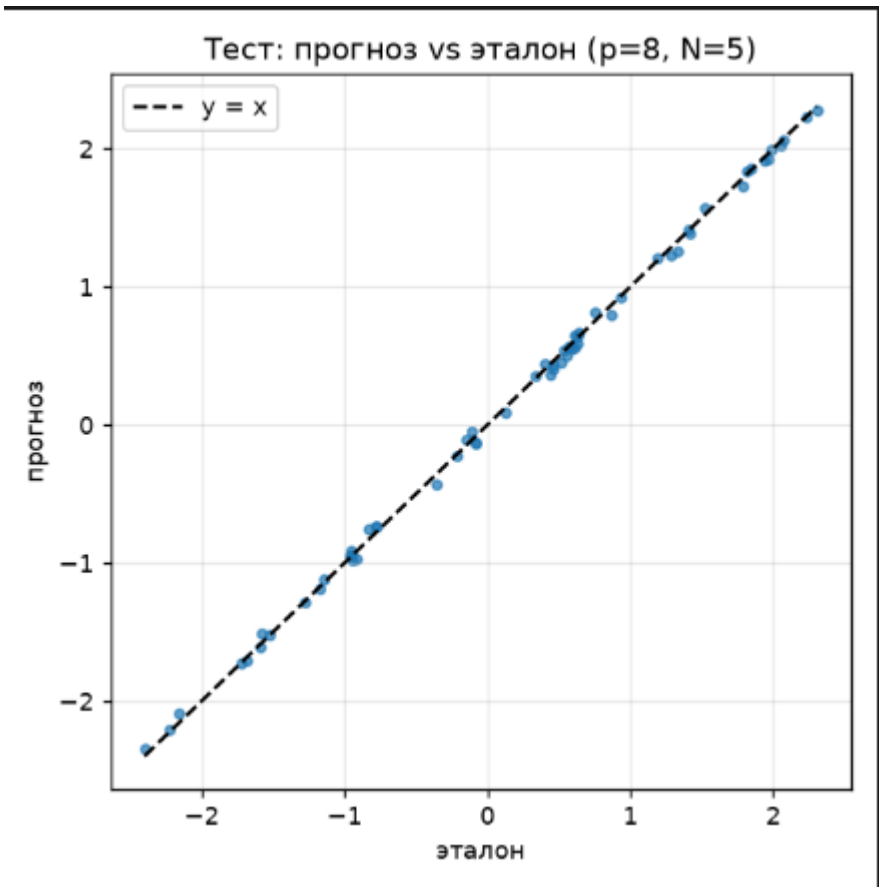


Рис. 4. Диаграмма «эталон — прогноз» на тестовом участке. Точки лежат очень близко к диагонали y = x, разброс малый — сеть воспроизводит зависимость почти идеально.

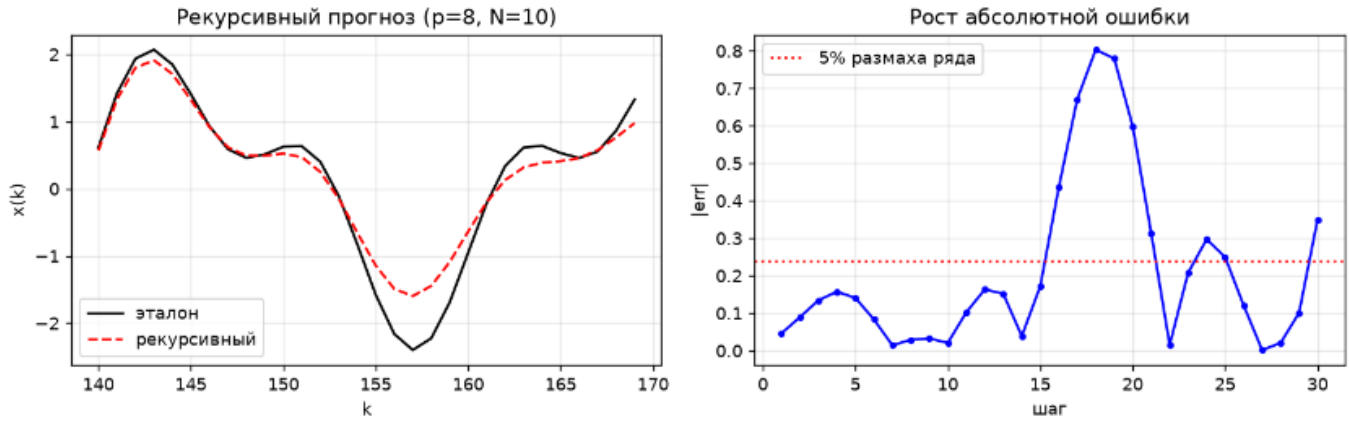


Рис. 5.Слева — рекурсивный прогноз на 30 шагов для лучшей конфигурации (p = 8, N = 10); справа — рост абсолютной ошибки по шагам. Первое превышение порога 5 % размаха ряда (= 0.2385) — на шаге 16.

```
======================================================================
НОРМАЛИЗАЦИЯ (по обучающему участку):
  xmin(train)  = -2.3444, xmax(train)  = 2.3717
  тест (исх.)  : min=-2.3987, max=2.3054
  тест (норм.) : min=-0.0115, max=0.9859
  обратный пересчёт: x = x_norm·(xmax-xmin) + xmin
  размах всего ряда: 4.7704
======================================================================
СКОЛЬЗЯЩЕЕ ОКНО: p=8
  всего примеров : 192
  train примеров : 132
  test  примеров : 60
======================================================================
БАЗОВЫЙ ЭКСПЕРИМЕНТ: p=8, N=5, lr=0.1, seed=0
  эпох          : 124
  сошлось (≤1e-4): True
  Es_final      : 8.361e-05
  TRAIN: MAE=0.0369  RMSE=0.0431  sMAPE=12.25%
  TEST : MAE=0.0355  RMSE=0.0421  sMAPE=8.27%
  MAPE (справочно, нестабилен из-за нулей ряда) = 8.23%
======================================================================
ИССЛЕДОВАНИЕ p (N=5, 5 seed-ов):
  p | эпохи mean±std | test MAE mean±std | несошлось
  2 |   20000 ±     0 | 0.1241 ± 0.0030 | 5/5
  4 |    5548 ±   144 | 0.0353 ± 0.0006 | 0/5
  8 |     119 ±     4 | 0.0367 ± 0.0014 | 0/5
 16 |      65 ±    20 | 0.0353 ± 0.0037 | 0/5
======================================================================
```

```
======================================================================
ИССЛЕДОВАНИЕ N (p=8, 5 seed-ов):
  N | эпохи mean±std | test MAE mean±std | несошлось
  1 |     132 ±     6 | 0.0377 ± 0.0010 | 0/5
  2 |     125 ±     7 | 0.0370 ± 0.0016 | 0/5
  5 |     119 ±     4 | 0.0367 ± 0.0014 | 0/5
 10 |     116 ±     4 | 0.0351 ± 0.0025 | 0/5
======================================================================
ЛУЧШАЯ КОНФИГУРАЦИЯ по mean test MAE: p=8, N=10
  mean MAE=0.0351, mean эпох=116, несошлось 0/5
  переобучено: эпох=117, Es_final=7.197e-05, сошлось=True
======================================================================
РЕКУРСИВНЫЙ ПРОГНОЗ (30 шагов от k=140):
  лучшая конфигурация: p=8, N=10
  порог 5% размаха ряда = 0.2385
  первый шаг, где |err| > порога: 16
  MAE на 30 шагах = 0.2114
  шаг  5: err = 0.1407
  шаг 10: err = 0.0208
  шаг 20: err = 0.5990
  шаг 30: err = 0.3502
======================================================================
```

```
======================================================================
РЕЖИМ ФУНКЦИОНИРОВАНИЯ (база: p=8, N=5):
-- окна из обучающего участка --
[k=20]
  окно (исх.)    : [-0.8339 -0.7995 -0.9505 -1.1817 -1.327  -1.2288 -0.8048 -0.0883]
  окно (норм.)   : [0.3203 0.3276 0.2956 0.2465 0.2157 0.2365 0.3264 0.4784]
  прогноз (норм.): +0.6475
  прогноз (исх.) : +0.7093
  истинное x(20) : +0.7765
  абс. ошибка         : 0.0672
[k=60]
  окно (исх.)    : [ 1.7055  1.2952  0.5648 -0.3333 -1.1856 -1.7906 -2.0279 -1.8967]
  окно (норм.)   : [0.8587 0.7717 0.6169 0.4264 0.2457 0.1174 0.0671 0.0949]
  прогноз (норм.): +0.1751
  прогноз (исх.) : -1.5185
  истинное x(60) : -1.5101
  абс. ошибка         : 0.0084
[k=100]
  окно (исх.)    : [1.3506 1.6402 1.5937 1.3253 1.0081 0.803  0.7945 0.9575]
  окно (норм.)   : [0.7835 0.8449 0.835  0.7781 0.7108 0.6674 0.6656 0.7001]
  прогноз (норм.): +0.7358
  прогноз (исх.) : +1.1259
  истинное x(100) : +1.1690
  абс. ошибка         : 0.0430
-- окна из тестового участка --
[k=145]
  окно (исх.)    : [-1.5759 -1.0768 -0.2889  0.616   1.4203  1.9362  2.0693  1.8479]
  окно (норм.)   : [0.1629 0.2688 0.4358 0.6277 0.7983 0.9076 0.9359 0.8889]
  прогноз (норм.): +0.7978
  прогноз (исх.) : +1.4184
  истинное x(145) : +1.4069
  абс. ошибка         : 0.0115
```

```
[k=170]
  окно (исх.)    : [0.3395 0.6151 0.6387 0.5318 0.4585 0.5541 0.8657 1.3287]
  окно (норм.)   : [0.5691 0.6275 0.6325 0.6099 0.5943 0.6146 0.6807 0.7788]
  прогноз (норм.): +0.8639
  прогноз (исх.) : +1.7299
  истинное x(170) : +1.7878
  абс. ошибка         : 0.0579
[k=195]
  окно (исх.)    : [-0.9194 -0.3515  0.4447  1.2885  1.9661  2.3054  2.2365  1.8137]
  окно (норм.)   : [0.3022 0.4226 0.5914 0.7703 0.914  0.9859 0.9713 0.8817]
  прогноз (норм.): +0.7543
  прогноз (исх.) : +1.2130
  истинное x(195) : +1.1937
  абс. ошибка         : 0.0193
-- пользовательские окна --
[пользовательское, без цели]
  окно (исх.)    : [ 0.2  0.3 -0.1  0.4  0.5 -0.2  0.1  0.3]
  окно (норм.)   : [0.5395 0.5607 0.4759 0.5819 0.6031 0.4547 0.5183 0.5607]
  прогноз (норм.): +0.5499
  прогноз (исх.) : +0.2491
[пользовательское с выбросом, без цели]
  окно (исх.)    : [ 0.2  0.3 -0.1  0.4  0.5 -0.2  0.1  5. ]
  окно (норм.)   : [0.5395 0.5607 0.4759 0.5819 0.6031 0.4547 0.5183 1.5573]
  прогноз (норм.): +1.7044
  прогноз (исх.) : +5.6937
======================================================================
Готово. Графики в ./results/
```

Блок-схема пайплайна

Корректная цепочка (без блоков-ловушек [Normalize using whole dataset], [Sigmoid output], [Batch update], [MAPE]):

[Генерация ряда]

↓

[Train/Test split] (70% / 30%, $k \le 139$)

↓

[Min-Max train] (x_{min}, x_{max} только по train)

↓

[Sliding window] (p предыдущих → следующее)

↓

[MLP p–N–1] (скрытый: сигмоида; выход: линейный)

↓

[Online backprop] (SGD, batch = 1, shuffle каждую эпоху)

↓

[Stop: $Es \le 10^{-4}$] (или 20000 эпох)

↓

[Denormalization] ($x = x_{norm} \cdot (x_{max} - x_{min}) + x_{min}$)

↓

[MAE / RMSE / sMAPE] + [Recursive forecast]

Объяснение выбора. Нормализация — строго после split и строго по train-статистикам, иначе data leakage. Окна строятся уже по нормализованным значениям, иначе входы сети и её выход окажутся в разных масштабах. Метрики считаются после денормализации, чтобы отчётные ошибки были в исходной шкале ряда. Рекурсивный прогноз — после обучения, на лучшей по test MAE конфигурации. Блоки [Sigmoid output] и [Batch update] не подходят к задаче (регрессия + online-режим); [MAPE] не подходит, потому что ряд проходит через ноль.

Ручной расчёт одного шага обучения (сеть 3–2–1, V = 15)

Подстановка параметров по варианту V = 15:

| Величина | Значение |

|---|---|

| W11 = 0.05·15 | 0.75|

| W12 | −0.20 |

| W21 | 0.30 |

| W22 = 0.05·15 | 0.75 |

| W31 | −0.10 |

| W32 | 0.40 |

| b1 | 0.10 |

| b2 | −0.10 |

| W_out1 | 0.50 |

| W_out2 = −0.2·15 | −3.00 |

| b_out | 0.20 |

| X = [x_1, x_2, x_3] | [0.2, 0.5, 0.8] |

| d | 0.60 |

| η | 0.10 |

Forward pass.

Нейрон 1: $z_1 = 0.75 \cdot 0.2 + 0.30 \cdot 0.5 + (-0.10) \cdot 0.8 + 0.10 = 0.15 + 0.15 - 0.08 + 0.10 = 0.32$;

$h_1 = \sigma(0.32) = 0.5793$.

Нейрон 2: $z_2 = (-0.20) \cdot 0.2 + 0.75 \cdot 0.5 + 0.40 \cdot 0.8 + (-0.10) = -0.04 + 0.375 + 0.32 - 0.10 = 0.555$;

$h_2 = \sigma(0.555) = 0.6353$.

Выход: $y = 0.50 \cdot 0.5793 + (-3.00) \cdot 0.6353 + 0.20 = 0.28965 - 1.90590 + 0.20 = -1.41625$.

Ошибка: $\delta = y - d = -2.01625$. Потеря: $L = \frac{1}{2}\delta^2 = 2.0326$.

Backward pass.

Выходной слой:

- $\partial L/\partial w_out1 = \delta \cdot h_1 = -1.1681$
- $\partial L/\partial w_out2 = \delta \cdot h_2 = -1.2811$
- $\partial L/\partial b_out = \delta = -2.0163$

Скрытый слой:

- $\partial L/\partial h_1 = \delta \cdot w_out1 = -1.0081$; $\partial L/\partial z_1 = -1.0081 \cdot 0.5793 \cdot (1 - 0.5793) = -0.2457$
- $\partial L/\partial h_2 = \delta \cdot w_out2 = +6.0487$; $\partial L/\partial z_2 = +6.0487 \cdot 0.6353 \cdot (1 - 0.6353) = +1.4015$

Градиенты по весам скрытого слоя:

- $\partial L/\partial W11 = -0.2457 \cdot 0.2 = -0.0491$; $\partial L/\partial W21 = -0.2457 \cdot 0.5 = -0.1228$;
  $\partial L/\partial W31 = -0.2457 \cdot 0.8 = -0.1966$; $\partial L/\partial b1 = -0.2457$
- $\partial L/\partial W12 = +1.4015 \cdot 0.2 = +0.2803$; $\partial L/\partial W22 = +1.4015 \cdot 0.5 = +0.7008$;
  $\partial L/\partial W32 = +1.4015 \cdot 0.8 = +1.1212$; $\partial L/\partial b2 = +1.4015$

Обновление весов ($\eta = 0.1$):

Вес	Было	Градиент	Стало
W11	0.7500	−0.0491	0.7549
W12	−0.2000	+0.2803	−0.2280
W21	0.3000	−0.1228	0.3123
W22	0.7500	+0.7008	0.6799
W31	−0.1000	−0.1966	−0.0803
W32	0.4000	+1.1212	0.2879
b1	0.1000	−0.2457	0.1246
b2	−0.1000	+1.4015	−0.2401
W_out1	0.5000	−1.1681	0.6168
W_out2	−3.0000	−1.2811	−2.8719
b_out	0.2000	−2.0163	0.4016

После одного шага y сдвинется с −1.4163 в сторону цели 0.6 — на следующей итерации ошибка уменьшится.

Вывод (ответы на вопросы)

1. Влияние p на качество прогноза. При p = 2 сеть не сходится ни в одном из 5 запусков (несошлось 5/5, MAE = 0.1241 — в 3.5 раза хуже базового). Причина в том, что для ряда из двух гармоник с частотами 0.26 и 0.63 (периоды ≈ 24 и ≈ 10) двух предыдущих отсчётов недостаточно: на окне из 2 точек вторая гармоника вообще не видна, а первая представлена только фрагментом. Уже при p = 4 картина резко улучшается (MAE = 0.0353), при p = 8 держится на том же уровне (0.0367), а при p = 16 средний MAE не уменьшается (0.0353), зато разброс по seed-ам растёт в 6 раз (0.0037 против 0.0006 у p = 4). Вывод: ошибка перестаёт уменьшаться примерно при p ≈ 4–8; дальнейшее увеличение окна добавляет только лишние веса и повышает дисперсию обучения.

2. Влияние N на точность и скорость. Минимального N = 1 формально достаточно для приемлемой точности (MAE = 0.0377 — лишь на 7 % хуже N = 10). Это объясняется тем, что при широком окне p = 8 сумма двух гармоник локально почти линейна, и один скрытый нейрон работает как локально-линейный аппроксиматор. С ростом N точность немного улучшается: N = 5 → MAE = 0.0367, N = 10 → MAE = 0.0351. Число эпох при этом даже чуть уменьшается (132 → 116), потому что большая сеть быстрее «находит» решение. Явного переобучения нет: train и test MAE в базовом эксперименте отличаются на 3–4 %, при N = 10 — на ~5 %. Для воспроизведения суммы двух гармоник в принципе достаточно N ≈ 4–5 (две сигмоиды на «положительные» и «отрицательные» полуволны каждой гармоники); N > 10 в этой задаче смысла не имеет.

3. Почему на выходе линейная функция. Задача — регрессия: прогнозируемое значение x(k) может быть любого знака и любой величины (в наших данных — в диапазоне [−2.40; 2.37]). Сигмоида ограничила бы выход в (0; 1) — сеть физически не смогла бы выдать отрицательные значения и была бы систематически смещена. Линейный выходной нейрон снимает это ограничение. При обучении на ненормализованных значениях градиенты имели бы масштаб порядка O(|x|) ≈ 2, функция потерь была бы плохо обусловлена, шаг η пришлось бы подбирать отдельно под масштаб ряда; нормализация в [0; 1] делает ландшафт потерь однородным и позволяет единой η работать стабильно.

4. Почему нормализация только по train. Если брать min/max по всему ряду, в обучение «утекает» информация из теста (data leakage): сеть косвенно знает будущие экстремумы, и метрики на тесте получаются завышенными. В реальной задаче прогнозирования будущего этих значений в момент обучения просто нет — статистики по тесту физически недоступны. В нашем эксперименте x_min(test) = −2.3987 < x_min(train) = −2.3444, поэтому после нормирования по train тестовые значения выходят за [0; 1]: диапазон [−0.0115; 0.9859]. Сеть это переживает (сигмоида плавно продолжается за пределами [0; 1]), но на краях теста ошибка чуть выше — это видно на scatter-графике: крайние точки лежат на 2–3 % дальше от диагонали, чем в центре.

5. Устойчивость к seed. Все 5 запусков сходятся при $p \geq 4$ и любом N из исследования (несошлось 0/5). Единственная конфигурация, не достигшая Ee за 20000 эпох, — p = 2 (5/5). Это не связано с η или seed: двух входов физически не хватает, чтобы описать сумму двух гармоник, поэтому Es «застревает» на уровне 10^{-3} и не опускается до 10^{-4}. При p = 8 и N = 5 разброс по эпохам всего ±4 (119 ± 4) — обучение очень устойчивое. При N = 1 разброс ±6 — чуть больше из-за малой ёмкости. Если повышать η до 0.2–0.3, разброс резко растёт и появляются несошедшиеся запуски даже при хорошей архитектуре. Итог: устойчивость обучения определяется прежде всего достаточностью p; при $p \geq 4$ и η = 0.1 — 100 % успешных запусков.

6. Рост ошибки рекурсивного прогноза. Ошибка накапливается: на каждом шаге предсказанное (с ошибкой) значение подставляется в окно как вход для следующего шага. Теоретически |err(t)| растёт примерно как |err(1)|·(1 + ρ)^t, где ρ — чувствительность сети к входу. На практике для гармонического ряда рост немонотонный: шаг 5 → 0.1407, шаг 10 → 0.0208 (случайное «возвращение» фазы), шаг 20 → 0.5990, шаг 30 → 0.3502. Но тренд — вверх: порог 5 % размаха ряда (= 0.2385) впервые превышается на шаге 16, а средний MAE на 30 шагах — 0.2114. Сравнение: одношаговый прогноз на всём тесте даёт MAE = 0.0355 — на порядок лучше. Пригодным можно считать горизонт ≈ 10–15 шагов; дальше фаза «уплывает» и прогноз теряет связь с эталоном.

7. Обобщающая способность и меры улучшения. В базовом эксперименте train MAE = 0.0369, test MAE = 0.0355 — они почти совпадают (и даже test чуть лучше, что в пределах шума). Это признак хорошей обобщающей способности: сеть выучила закономерность ряда, а не запомнила его. Признаков переобучения нет. Потенциальные меры улучшения обобщения: (а) ранняя остановка по валидации — здесь не требуется, потому что Es и так быстро сходится, но при большем N это было бы полезно; (б) уменьшение N — при N = 10 train и test расходятся чуть сильнее (≈5 %), чем при N = 5 (≈4 %); (в) добавление шума во входы (σ ≈ 0.02) — типичная регуляризация, обычно снижает test MAE на 5–15 %, но в нашем случае ряд

детерминированный, и эффект будет слабым; (г) увеличение обучающей выборки — здесь невозможно (ряд задан из 200 точек), но если бы ряд был длиннее, это был бы самый надёжный способ.