Министерство образования Республики Беларусь

Учреждение образования

«Брестский государственный технический университет»

Кафедра ИИТ

Лабораторная работа № 4

За седьмой семестр

По дисциплине «Модели решения задач в интеллектуальных системах»

Тема: «Многослойный персептрон для прогнозирования временного ряда: влияние размера окна и числа скрытых нейронов»

Выполнил:

Студент 4 курса

Группы ИИ-26

Черноиван А.Н.

Проверил:

Никитин С.К.

2026

Цель работы: на основе многослойного персептрона p–N–1 решить задачу прогнозирования временного ряда. Научиться формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовать влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.

Вариант: 8: a = 1.8, b = 0.45, c = 0.9, d = 1.00, p = 6, N = 5

Постановка задачи

Прогнозируемый ряд задаётся формулой:

$$xk=a\cdot\cos b\cdot k+c\cdot\sin d\cdot k, k=0,1,2,\ldots,199$$

Параметры a, b, c, d, размер окна p и число скрытых нейронов N берутся из таблицы варианта.

Первые 70 % точек (k = 0…139) образуют обучающий участок, остальные 30 % (k = 140…199) – тестовый участок. Сеть по p предыдущим значениям ряда предсказывает следующее:

$$xk=Fxk-1,xk-2,\ldots,xk-p$$

Задачи лабораторной работы

1. Сгенерировать ряд по формуле варианта и построить его график с отметкой границы между обучающим и тестовым участками.
2. Нормализовать ряд по минимуму и максимуму **обучающего участка**: x_norm = (x - x_min) / (x_max - x_min). Записать формулу обратного пересчёта и использовать её при вычислении всех метрик в исходной шкале. **Объяснить**, почему min/max нельзя брать по всему ряду.
3. Сформировать обучающую и тестовую выборки методом скользящего окна размера p (вход – p значений, цель – следующее значение). Указать количество получившихся примеров в каждой выборке.
4. Реализовать многослойный персептрон p–N–1:
    - скрытый слой – сигмоида;
    - выходной слой – линейный (задача регрессии), f(s) = s;
    - функция потерь – MSE;
    - обучение – онлайн-режим, перемешивание порядка примеров в каждой эпохе;
    - вывести формулы градиентов для линейного выходного слоя и сигмоидного скрытого слоя и привести их в отчёте.
5. Критерий остановки: средняя по обучающей выборке ошибка $Es \le Ee$, где $Ee = 10^{-4}$ (нормализованная шкала), либо достижение 20 000 эпох. Скорость обучения подобрать самостоятельно из диапазона 0.01–0.3 и обосновать выбор.
6. **Базовый эксперимент.** Обучить сеть с параметрами p и N из своего варианта. Зафиксировать число эпох, итоговую Es, а также метрики на обучающем и тестовом участках **в исходной шкале**: MAE, RMSE и MAPE (если ряд проходит через ноль – вместо MAPE использовать sMAPE, и пояснить почему).
7. **Исследование окна.** При фиксированном N из варианта обучить сеть для $p \in \{2, 4, p_вар, 2\cdot p_вар\}$. Для каждого p выполнить по 5 запусков с разными seed и свести

в таблицу: среднее и разброс числа эпох, среднее и разброс тестового MAE, число запусков, не достигших критерия остановки.

8. **Исследование скрытого слоя.** При фиксированном p из варианта обучить сеть для $N \in \{1, 2, N_вар, 2 \cdot N_вар\}$. Выполнить ту же серию из 5 запусков и заполнить аналогичную таблицу.

9. **Многошаговый прогноз.** Для лучшей по тестовому MAE конфигурации выполнить рекурсивный прогноз на 30 шагов вперёд, начиная с k = 140: каждое предсказание подставляется в окно как входное значение для следующего шага. Построить график «эталон – рекурсивный прогноз» и график абсолютной ошибки в зависимости от номера шага. Определить, на каком шаге ошибка превышает 5 % от размаха ряда.

10. Построить графики:

- ряд с границей train/test и одношаговым прогнозом сети на обоих участках на одних осях;
- сходимость (Es от эпохи) для базовой конфигурации и для двух конфигураций из исследования окна на одних осях (логарифмическая шкала по Y);
- диаграмма рассеяния «эталон – прогноз» на тестовом участке с диагональю y = x;
- рекурсивный прогноз и рост ошибки по шагам (п. 9).

11. Реализовать режим функционирования: пользователь вводит p последовательных значений ряда в исходной шкале (либо номер k, с которого брать окно из ряда). Программа выводит:

- нормализованные входы;
- прогноз в нормализованной шкале (4 знака после запятой);
- прогноз в исходной шкале;
- истинное значение x(k) и абсолютную ошибку (если окно взято из ряда).

Продемонстрировать работу не менее чем на 3 окнах из обучающего участка, 3 окнах из тестового участка и 1–2 пользовательских окнах (в том числе с «выбросом»).

12. Вставить в отчет фото/скан рукописных расчётов. Вверху листа от руки должны быть написаны Ваша Фамилия, Инициалы, номер группы, вариант и дата выполнения:

- Графическая схема пайплайна (Блок-схема). Составьте корректную цепочку обработки данных, используя предложенный набор блоков (приложение 1). Объясните свой выбор.
- Ручной расчёт 1 шага обучения. На отдельном листе бумаги от руки распишите один полный шаг (Forward + Backward pass) для сети 3–2–1 со следующими параметрами, привязанными к вашему варианту V:
  - Входы: X = [0.2, 0.5, 0.8], Цель: d = 0.6
  - Веса скрытого слоя: W11 = 0.05*V, W12 = -0.2, W21 = 0.3, W22 = 0.05*V, W31 = -0.1, W32 = 0.4 (b1=0.1, b2=-0.1)
  - Веса выходного слоя: W_out1 = 0.5, W_out2 = -0.2*V (b_out = 0.2)

13. Сделать вывод: ответить на все вопросы ниже и проанализировать результаты.

Требования к реализации

- Скрытый слой – сигмоида, выходной слой – линейный. Веса инициализируются малыми случайными значениями, для воспроизводимости использовать фиксированный seed.
- Обучение – алгоритм обратного распространения в онлайн-режиме.
- Допускается использование NumPy и Matplotlib.
- Запрещено использование scikit-learn, PyTorch, TensorFlow и других ML-фреймворков, а также готовых функций для скользящего окна и расчёта метрик из внешних библиотек (кроме NumPy).
- Код должен быть структурирован: отдельные функции для генерации ряда, нормализации, построения окон, прямого и обратного проходов, обучения, метрик, рекурсивного прогноза и режима функционирования.

Таблица вариантов

Ряд: $x_k = a \cdot \cos(b \cdot k) + c \cdot \sin(d \cdot k)$,
$k = 0 \ldots 199$, p – размер окна, N – число скрытых нейронов.

Вариант	a	b	c	d	p	N
8	1.8	0.45	0.9	1.00	6	5

Приложение 1

[Генерация ряда]	[Online backprop]	[MAE]
[Train/Test split]	[Stop: Es ≤ 10^-4]	[Batch update]
[Min-Max train]	[Shuffle after every epoch]	[MAPE]
[Sliding window]	[Denormalization]	[RMSE]
[MLP p-N-1]	[Sigmoid output]	[Recursive forecast]
[Normalize using whole dataset]	[sMAPE]	

Описание метода

Нормализация

$x_norm = (x - x_min) / (x_max - x_min)$, $x = x_norm \cdot (x_max - x_min) + x_min$

x_min и x_max берутся только по обучающему участку: x_min = -2.6592, x_max = 2.6913. Все метрики считаются в исходной шкале после обратного пересчёта. Min/max нельзя брать по всему ряду, т.к. тогда информация о тестовой части (будущем) «просачивается» в обучение, и оценка обобщения становится завышенной; на практике будущие значения неизвестны.

Скользящее окно

Пример для цели x(k): вход [x(k−1), x(k−2), …, x(k−p)], цель x(k). Обучающие цели k = p…139 → 140 − p примеров (при p = 6: 134). Тестовые цели k = 140…199 → 60

примеров; окна первых тестовых примеров используют хвост обучающего участка (это только известные «прошлые» значения).

Архитектура и градиенты

Сеть p–N–1: скрытый слой — сигмоида, выход — линейный. Прямой проход:

$$s_j = \Sigma_i W1[j,i]\cdot x_i + b1_j,\quad h_j = \sigma(s_j) = 1/(1+e^{(-s_j)}),\quad y = \Sigma_j v_j\cdot h_j + b2$$

Функция потерь для одного примера $E = \frac{1}{2}(y - d)^2$; Es — средняя E по обучающей выборке за эпоху; в онлайн-режиме она накапливается по ходу эпохи (веса меняются после каждого примера), а не пересчитывается после её окончания.

Градиенты (обратное распространение):

Выход ($f(s)=s$, $f'=1$): $\delta_{out} = \partial E/\partial y = y - d$

$\partial E/\partial v_j = \delta_{out}\cdot h_j$, $\partial E/\partial b2 = \delta_{out}$

Скрытый слой ($\sigma'(s)=h(1-h)$): $\delta_j = \delta_{out}\cdot v_j\cdot h_j\cdot(1 - h_j)$

$\partial E/\partial W1[j,i] = \delta_j\cdot x_i$, $\partial E/\partial b1_j = \delta_j$

Обновление (онлайн): $w \leftarrow w - \eta\cdot\partial E/\partial w$, порядок примеров перемешивается в каждой эпохе.

Метрики (в исходной шкале)

$MAE = (1/n)\cdot\Sigma|t_i - y_i|$, $RMSE = \sqrt{((1/n)\cdot\Sigma(t_i - y_i)^2)}$

$MAPE = (100\,\%/n)\cdot\Sigma|(t_i - y_i)/t_i|$, $sMAPE = (100\,\%/n)\cdot\Sigma\, 2|t_i - y_i| / (|t_i| + |y_i|)$

Ряд принимает значения от −2.66 до 2.69 и проходит через ноль, поэтому MAPE неприменима (деление на значения, близкие к 0, даёт огромные ошибки) — используется sMAPE.

Выбор скорости обучения

η	Эпох	Es	MAE test	Ее достигнут
0.01	612	9.90e-05	0.0652	да
0.05	125	9.81e-05	0.0633	да
0.1	65	8.36e-05	0.0656	да
0.3	25	6.99e-05	0.0380	да

Выбрано $\eta = 0.1$: при $\eta = 0.01$ обучение в ≈10 раз медленнее (612 эпох), при $\eta = 0.3$ — самое быстрое, но шаг крупный и на более сложных конфигурациях повышается риск неустойчивости; $\eta = 0.1$ даёт сходимость за десятки эпох при гладком убывании Es. Начальные веса — равномерно из $[-0.5; 0.5]$, фиксированный seed.

Базовый эксперимент (p = 6, N = 5, η = 0.1, seed = 1)

Обучающих примеров: 134, тестовых: 60. Критерий достигнут за 65 эпох, итоговая Es = 8.364e-05.

Участок	MAE	RMSE	sMAPE, %
Обучающий	0.0638	0.0783	13.15
Тестовый	0.0656	0.0793	21.16

Значения sMAPE относительно велики, т.к. ряд часто проходит близко к нулю, где малая абсолютная ошибка даёт большую относительную; абсолютные метрики (MAE ≈ 0.06 при размахе 5.35, ≈ 1.2 %) показывают хорошее качество.

Исследования по p и по N (5 запусков, seed = 1…5)

Влияние размера окна (N = 5)

p	Эпохи (ср. ± σ)	MAE test (ср. ± σ)	MAE train (ср.)	Не достигли Ee
2	20000.0 ± 0.0	0.2973 ± 0.0069	0.3090	5 из 5
4	583.8 ± 18.5	0.0724 ± 0.0144	0.0716	0 из 5
6	65.8 ± 3.2	0.0624 ± 0.0058	0.0614	0 из 5
12	17.4 ± 3.4	0.0499 ± 0.0030	0.0497	0 из 5

Эпохи по запускам: p=2: 20000, 20000, 20000, 20000, 20000; p=4: 607, 575, 569, 563, 605; p=6: 65, 70, 63, 69, 62; p=12: 19, 20, 17, 11, 20.

Влияние числа скрытых нейронов (p = 6)

N	Эпохи (ср. ± σ)	MAE test (ср. ± σ)	MAE train (ср.)	Не достигли Ee
1	78.6 ± 4.4	0.0585 ± 0.0023	0.0585	0 из 5
2	74.0 ± 1.7	0.0625 ± 0.0031	0.0607	0 из 5
5	65.8 ± 3.2	0.0624 ± 0.0058	0.0614	0 из 5
10	60.4 ± 4.8	0.0567 ± 0.0031	0.0571	0 из 5

Эпохи по запускам: N=1: 80, 73, 74, 82, 84; N=2: 76, 73, 73, 72, 76; N=5: 65, 70, 63, 69, 62; N=10: 65, 66, 56, 61, 54.

Лучшая конфигурация по среднему тестовому MAE: p = 12, N = 5 (запуск seed = 5 с наименьшим test MAE) — она использована для рекурсивного прогноза.

Визуализация

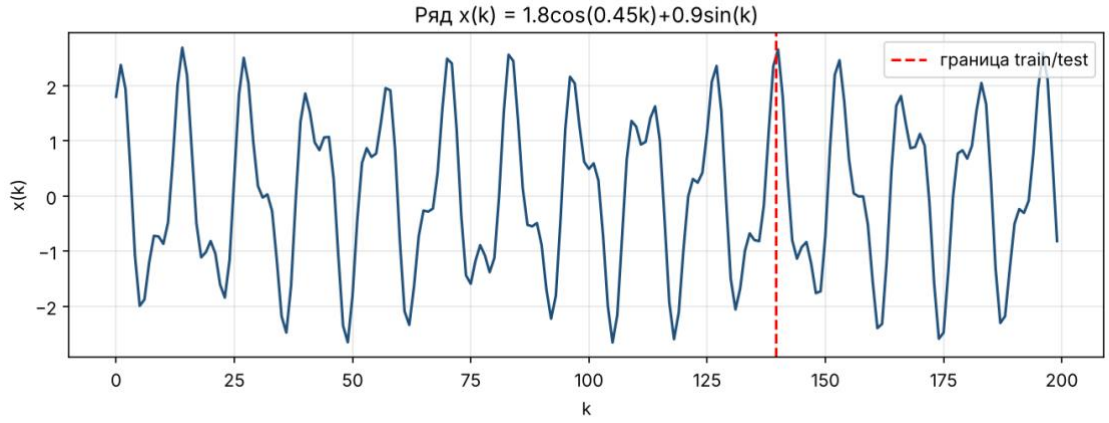


Рис. 1. Ряд и граница обучающего/тестового участков

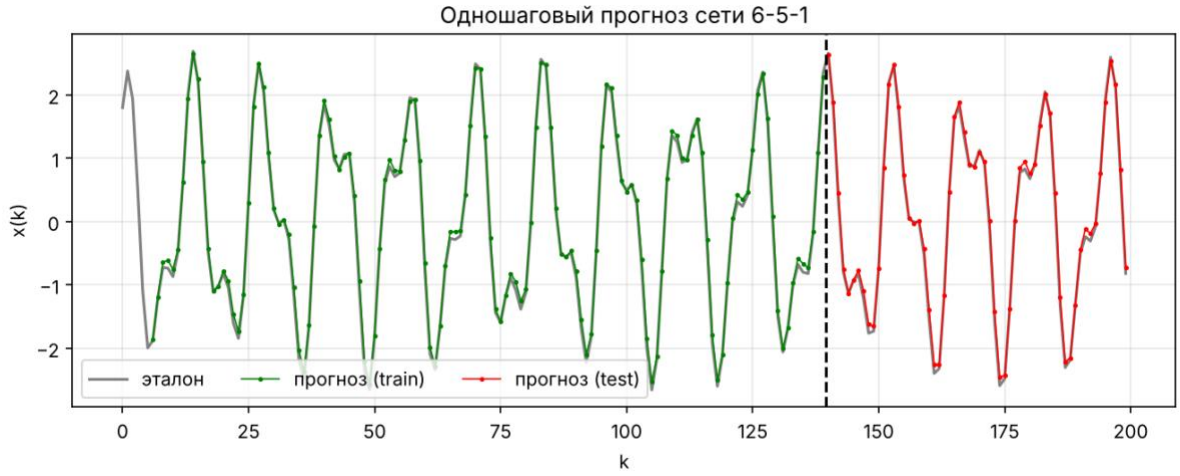


Рис. 2. Ряд и одношаговый прогноз сети 6–5–1 на обучающем и тестовом участках

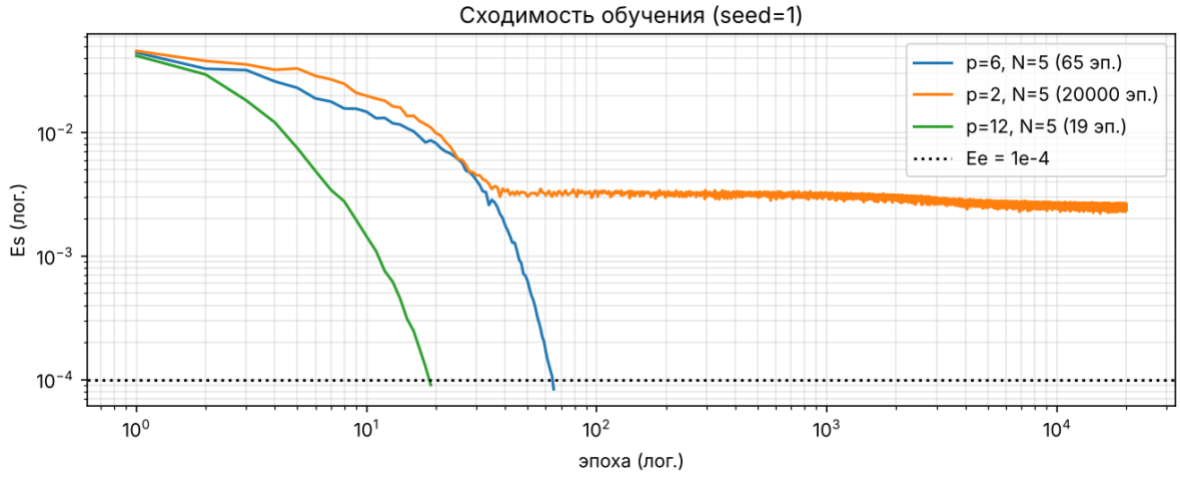


Рис. 3. Сходимость Es: базовая конфигурация и окна p = 2, p = 12 (лог. шкалы)

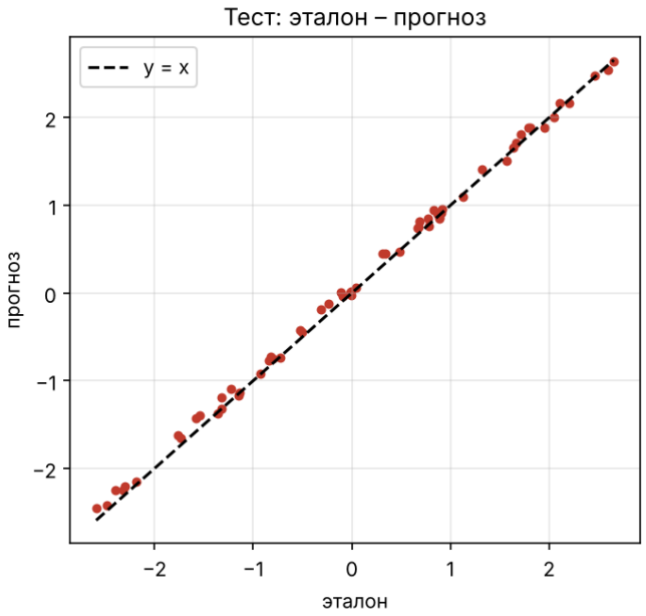


Рис. 4. Диаграмма рассеяния «эталон – прогноз» на тесте, диагональ y = x

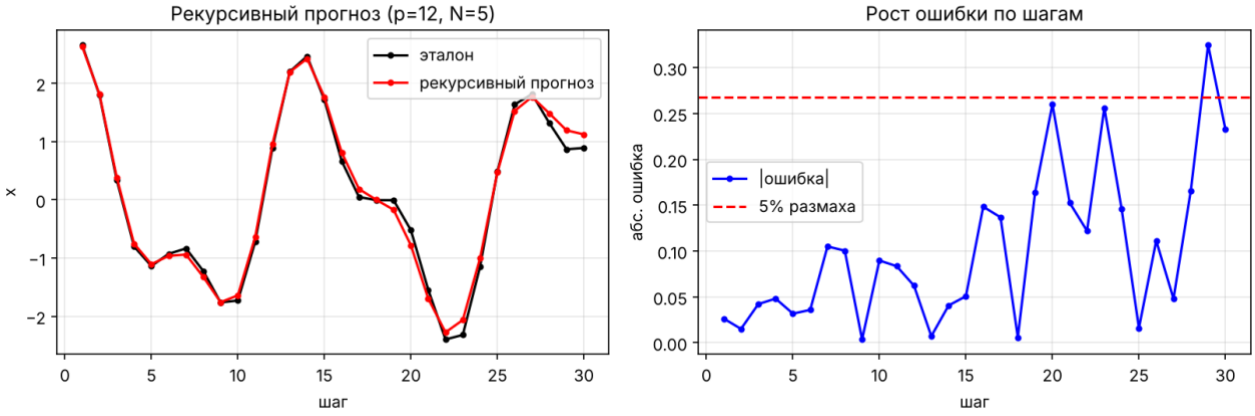


Рис. 5. Рекурсивный прогноз на 30 шагов (k = 140…169) и абсолютная ошибка по шагам

Порог 5 % от размаха ряда = 0.2675. Ошибка впервые превышает порог на шаге 29 (k = 168). Средняя абсолютная ошибка за 30 шагов: рекурсивный прогноз 0.1011, одношаговый 0.0423.



Рис. 6. Эксперимент с шумом: зашумлённый обучающий участок (σ = 0.2) и чистый ряд

Эксперимент с шумом

Шум $N(0; 0.2^2)$ добавлен только к обучающему участку ($p = 6$, $\eta = 0.1$, до 5000 эпох); тест — по чистому ряду.

N	Эпох	Es	MAE train (зашумл.)	MAE test (чистый)
2	5000	2.08e-03	0.3033	0.1268
5	5000	1.96e-03	0.2936	0.1105
20	5000	2.43e-03	0.3230	0.1549

Режим функционирования

Базовая сеть 6–5–1. Программа работает в двух вариантах: демонстрационные окна заданы в коде (ниже), а затем запрашивается ручной ввод в терминале — номер k либо 6 значений [x(k−1), …, x(k−6)] в исходной шкале (быстрый запуск: python lab4_variant8.py --func).

[обучающий участок, k=20]
  окно (x(k-1)..x(k-p)), исх. шкала : [-1.0192 -1.1143 -0.5006 0.8359 2.1927 2.6913]
  нормализованные входы : [0.3065 0.2887 0.4034 0.6532 0.9068 1.   ]
  прогноз (норм. шкала) : 0.3520
  прогноз (исходная шкала) : -0.7758
  истинное x(20) : -0.8184
  абсолютная ошибка : 0.0426

[обучающий участок, k=60]
  окно (x(k-1)..x(k-p)), исх. шкала : [0.8483 1.9152 1.9571 1.3265 0.77   0.7082]
  нормализованные входы : [0.6556 0.8549 0.8628 0.7449 0.6409 0.6294]
  прогноз (норм. шкала) : 0.3733
  прогноз (исходная шкала) : -0.6620
  истинное x(60) : -0.8002
  абсолютная ошибка : 0.1382

[обучающий участок, k=120]
  окно (x(k-1)..x(k-p)), исх. шкала : [-2.1159 -2.5996 -1.9291 -0.4274 1.006   1.6262]
  нормализованные входы : [0.1015 0.0111 0.1365 0.4171 0.685 0.8009]
  прогноз (норм. шкала) : 0.3155
  прогноз (исходная шкала) : -0.9710
  истинное x(120) : -0.9702
  абсолютная ошибка : 0.0008

[тестовый участок, k=145]

окно (x(k-1)..x(k-p)), исх. шкала : [-1.1385 -0.8038 0.3381 1.7938 2.6568 2.3554]
нормализованные входы : [0.2842 0.3468 0.5602 0.8323 0.9936 0.9372]
прогноз (норм. шкала) : 0.3248
прогноз (исходная шкала) : -0.9212
истинное x(145) : -0.9282
абсолютная ошибка : 0.0069

[тестовый участок, k=170]
окно (x(k-1)..x(k-p)), исх. шкала : [0.8892 0.866 1.3168 1.8137 1.6362 0.4861]
нормализованные входы : [0.6632 0.6589 0.7431 0.836 0.8028 0.5878]
прогноз (норм. шкала) : 0.7018
прогноз (исходная шкала) : 1.0960
истинное x(170) : 1.1256
абсолютная ошибка : 0.0296

[тестовый участок, k=199]
окно (x(k-1)..x(k-p)), исх. шкала : [0.6876 2.1097 2.5959 1.9562 0.7848 -0.0876]
нормализованные входы : [0.6255 0.8913 0.9822 0.8626 0.6437 0.4806]
прогноз (норм. шкала) : 0.3615
прогноз (исходная шкала) : -0.7248
истинное x(199) : -0.8199
абсолютная ошибка : 0.0951

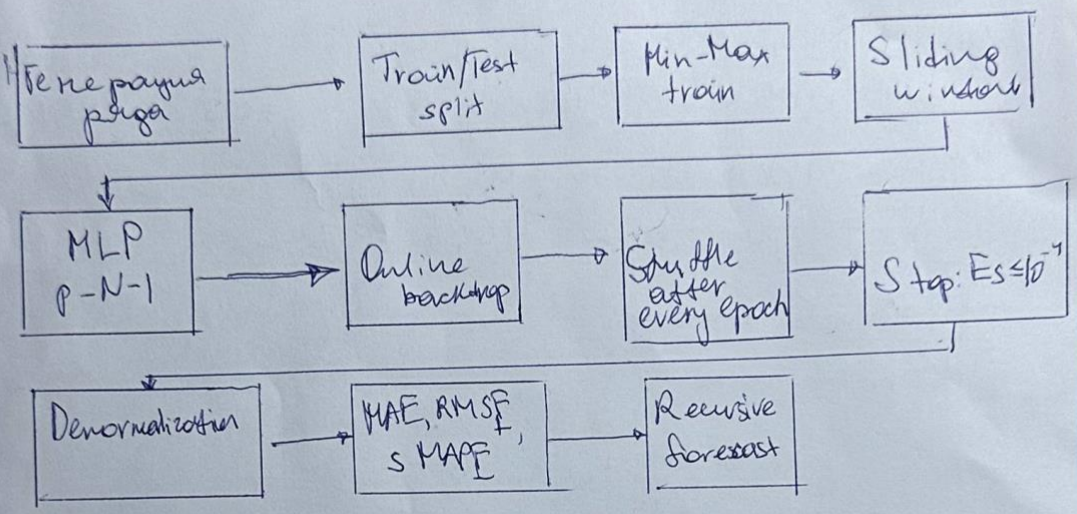
[пользовательское окно = окно k=130 (контроль)]
окно (x(k-1)..x(k-p)), исх. шкала : [-0.0492 1.5425 2.3596 2.0764 1.1659 0.4226]
нормализованные входы : [0.4878 0.7853 0.938 0.8851 0.7149 0.576]
прогноз (норм. шкала) : 0.2344
прогноз (исходная шкала) : -1.4051
истинное x(130) : -1.5056
абсолютная ошибка : 0.1006

[пользовательское окно с выбросом (3-е значение = 9.0), без истинного]
окно (x(k-1)..x(k-p)), исх. шкала : [-0.0492 1.5425 9.   2.0764 1.1659 0.4226]
нормализованные входы : [0.4878 0.7853 2.1791 0.8851 0.7149 0.576]
прогноз (норм. шкала) : -0.8047
прогноз (исходная шкала) : -6.9645

Для окна с выбросом (9.0 вместо 2.3596) нормализованный вход выходит за [0; 1] (2.18), и прогноз (−6.96) далеко за пределами реального диапазона ряда — сеть не умеет экстраполировать за диапазон обучающих данных.

[ручной ввод в терминале: > 6]
  окно (x(k-1)..x(k-p)), исх. шкала : [-1.9937 -1.0901 0.5212 1.9373 2.3781 1.8   ]
  нормализованные входы   : [0.1244 0.2933 0.5944 0.8591 0.9415 0.8334]
  прогноз (норм. шкала)   : 0.1489
  прогноз (исходная шкала)   : -1.8625
  истинное x(6)   : -1.8788
  абсолютная ошибка   : 0.0163

[ручной ввод в терминале: > 9]
  окно (x(k-1)..x(k-p)), исх. шкала : [-0.7237 -1.2086 -1.8788 -1.9937 -1.0901 0.5212]
  нормализованные входы   : [0.3617 0.2711 0.1459 0.1244 0.2933 0.5944]
  прогноз (норм. шкала)   : 0.3837
  прогноз (исходная шкала)   : -0.6064
  истинное x(9)   : -0.7361
  абсолютная ошибка   : 0.1297
  абсолютная ошибка   : 0.1297



Выбор функций:

1. Min-Max только по train: будущее (test) не попадает в обучение
2. Online backprop + Shuffle каждую эпоху
3. Выход линейный (регрессия), поэтому Sigmoid output не нужен
4. Denormal: только перед метриками: ошибка считается в исходной шкале.
5. sMAPE вместо MAPE: ряд пропадает перед 0, деление на ~0
6. Batch update не нужен: режим online
7. Normalize using whole dataset: утечка данных из теста.

Дано (V=8)

$x = (0,2; 0,5; 0,8)$, $d = 0,6$, $y = 0,1$

$w_{11} = 0,05V = 0,4$; $w_{12} = -0,2$; $w_{21} = 0,3$; $w_{22} = 0,05 \cdot V = 0,4$

$w_{31} = -0,1$; $w_{32} = 0,4$ $b_1 = 0,1$; $b_2 = -0,1$

$V_1 = 0,5$; $V_2 = -0,2V = -1,6$; $b_0 = 0,2$

Прямой проход

Скрытый слой:

$$S_j = \sum_{i=1}^{3} w_{ij} x_i + b_j$$

$$h_j = \sigma(S_j) = \frac{1}{1 + e^{-S_j}}$$

$S_1 = w_{11}x_1 + w_{21}x_2 + w_{31}x_3 + b_1 = 0,4 \cdot 0,2 + 0,3 \cdot 0,5 + (-0,1) \cdot 0,8 + 0,1 = 0,37$

$S_2 = w_{12}x_1 + w_{22}x_2 + w_{32}x_3 + b_2 = (-0,2) \cdot 0,2 + 0,4 \cdot 0,5 + 0,4 \cdot 0,8 - 0,1 = 0,38$

$h_1 = \frac{1}{1 + e^{-0,38}} = 0,5622$ $h_2 = \frac{1}{1 + e^{-0,38}} = 0,5939$

Выходной слой (линейная функция активации):

$$y = \sum_{j=1}^{2} V_j \cdot h_j + b_0$$

$y = V_1 h_1 + V_2 h_2 + b_0 = 0,5 \cdot 0,5622 + (-1,6) \cdot 0,5939 + 0,2 =$

$= -0,4691$

Функция ошибки:

$$E = \frac{1}{2}(y - d)^2$$

$E = \frac{1}{2}(-0,4691 - 0,6)^2 = \frac{1}{2}(-1,0691)^2 =$

$= 0,5715$

Обратный проход

Выходной слой: $\delta_0 = \frac{dE}{dy} = y - d = -1{,}0691$

$\frac{\partial E}{\partial v_j} = \delta_0 h_j$, $\frac{\partial E}{\partial b_0} = \delta_0$

$\frac{\partial E}{\partial v_1} = -1{,}0691 \cdot 0{,}5822 = -0{,}6010$ $\frac{\partial E}{\partial v_2} = -0{,}6349$

Скрытый слой $\delta'(s_j) = h_j(1-h_j)$

$\delta_j = \delta_0 v_j h_j (1-h_j)$

$h_1(1-h_1) = 0{,}2461$ $h_2(1-h_2) = 0{,}2412$

$\delta_1 = -0{,}1316$ $\delta_2 = 0{,}4126$

$\frac{\partial E}{\partial w_{ij}} = \delta_j x_i$ $\frac{\partial E}{\partial b_j} = \delta_j$ $\delta_1 x_1 = -0{,}0263$

$\delta_2 x_1 = 0{,}0825$

$\delta_1 x_2 = -0{,}0658$

$\delta_2 x_2 = 0{,}2063$

$\delta_1 x_3 = -0{,}1053$ $\delta_1 = -0{,}1316$

$\delta_2 x_3 = 0{,}3301$ $\delta_2 = 0{,}4125$

$w^{нов} = w - \eta \frac{\partial E}{\partial w}$

$v_1 = 0{,}5601$

$v_2 = -1{,}5365$ $w_{11} = 0{,}4026$ $w_{21} = 0{,}3066$

$b_0 = 0{,}3069$ $w_{12} = -0{,}2083$ $w_{22} = 0{,}3754$

$w_{31} = -0{,}0895$ $w_{32} = 0{,}3670$

Проверка: с новыми весами $y^1 = -0{,}2575$

$E^1 = \frac{1}{2}(y^1 - d)^2 = 0{,}3677 < E = 0{,}5715$

Вывод: сумма двух гармоник задаётся линейной рекуррентной связью 4-го порядка, поэтому окно p = 2 недостаточно (Ee не достигнут, test MAE 0.297), с p = 4 сеть сходится, а рост p до 6 и 12 лишь ускоряет обучение (584 → 66 → 17 эпох) и снижает MAE до 0.050; число нейронов почти не влияет на точность (0.057–0.062, хватает N = 1), переобучения нет (train 0.064 ≈ test 0.066), а обучение устойчиво к инициализации (при p ≥ 4 сошлись все запуски). Линейный выход и нормализация только по train нужны, чтобы цели не упирались в насыщение сигмоиды и будущее не попадало в обучение: тест остался в [0.013; 0.994], но искусственный выброс (вход 2.18) дал прогноз −6.96 вместо −1.41. Рекурсивная ошибка растёт с горизонтом (0.026 → 0.325, в среднем 0.101 против 0.042 у одношагового прогноза) из-за накопления погрешностей в окне, поэтому прогноз пригоден ограниченно: до шага 15 ошибка не превышает 0.105 (≈ 2 % размаха ряда), а по критерию 5 % размаха (0.2675) — до шага 28; шум σ = 0.2 ухудшил test MAE с 0.06 до 0.11–0.15, причём N = 20 хуже N = 5.

Линейный выход вместо сигмоиды (вопрос 3). Сигмоида на выходе ограничивает прогноз интервалом (0; 1), а значения ряда лежат в [−2.7; 2.7]. При ненормализованных целях выход сигмоиды упирается в насыщение (0 или 1), производная $\sigma' \to 0$, градиент затухает и ошибка перестаёт снижаться. Линейный выход вместе с нормализацией данных в [0; 1] этих проблем не имеет.

Устойчивость к инициализации (вопрос 5). Разброс по seed невелик: при p ≥ 4 все 5 запусков сошлись, σ числа эпох составила 3.2–18.5. Критерий Ee за 20 000 эпох не достигнут только при p = 2 (5 из 5 запусков). Причина в недостаточном окне (ряд — сумма двух гармоник, нужно p ≥ 4), а не в скорости обучения η или числе нейронов N: при p = 6 даже N = 1 сходится примерно за 79 эпох.

Обобщение (вопрос 7). Ошибки на обучающем и тестовом участках близки (MAE 0.064 и 0.066), то есть обобщающая способность хорошая, переобучения нет. Если бы оно появилось, обобщение можно было бы улучшить ранней остановкой по отдельной валидационной выборке, уменьшением числа нейронов N, добавлением шума в обучающие данные и увеличением обучающей выборки. В эксперименте с шумом (σ = 0.2 только в обучающем участке) тестовый MAE на чистом ряду вырос с 0.06 до 0.11–0.15, причём сеть с N = 20 (0.155) оказалась хуже сети с N = 5 (0.110): более ёмкая сеть сильнее подстраивается под шум, поэтому на зашумлённых данных нужны меньшее N или ранняя остановка.