Министерство образования Республики Беларусь

Учреждение образования

«Брестский государственный технический университет»

Кафедра ИИТ

Лабораторная работа № 3

За седьмой семестр

Тема: «Многослойный персептрон для XOR с ReLU на скрытых слоях: сравнение активационных функций»

Выполнил:

Студент 4 курса

Группы ИИ-26

Шарубнёв Д. С.

Проверил:

Никитин С.К.

2026

Вариант 9

Цель: На основе многослойного персептрона архитектуры 2-2-1 из ЛР №2, исследовать влияние активационной функции ReLU (Rectified Linear Unit) на скрытых слоях. Провести сравнительный анализ обучения сети с функцией активации Сигмоида (базовая конфигурация) и ReLU (новая конфигурация) по скорости сходимости, качеству обучения, форме разделяющей поверхности и устойчивости к инициализации весов.

Задачи лабораторной работы

1. Взять за основу код многослойного персептрона 2-2-1 с функцией потерь BCE из ЛР №2.
2. Реализовать активационную функцию ReLU на скрытом слое и осуществить корректное обратное распространение ошибки для ReLU. На выходном слое оставить Сигмоиду.
3. Обучить сеть на полной таблице истинности в двух конфигурациях:
   - Конфигурация A (базовая): MLP 2-2-1, Сигмоида на всех слоях, BCE, нормализованные целевые значения (0/1);
   - Конфигурация B (новая): MLP 2-2-1, ReLU на скрытом слое, Сигмоида на выходном, BCE, нормализованные (0/1).
4. Критерий остановки для обеих конфигураций: суммарная ошибка $Es \leq Ee$ (как в ЛР №2).
5. Для каждой конфигурации зафиксировать:
   - Количество эпох до критерия остановки.
   - Итоговую суммарную ошибку и accuracy.
   - Среднюю абсолютную ошибку в исходной шкале [c0; c1].
6. Провести не менее 5 запусков обучения для каждой конфигурации с разными seed и сравнить устойчивость.
7. Построить графики:
   - График сходимости (суммарная ошибка Es от эпохи) для обеих конфигураций на одних осях.
   - Диаграмма разброса числа эпох по 5 запускам (столбики) для конфигурации A и B.
8. Визуализация разделяющей поверхности:
   - Для представительного экземпляра каждой конфигурации построить карту (heatmap) выходного значения сети на плоскости $(A, B) \in [-10; 10]^2$ с наложением 4 точек обучающей выборки.
   - Описать, как ReLU изменяет форму разделяющей поверхности (кусочно-линейные границы vs гладкие).
9. Реализовать режим функционирования сети:
   - Пользователь вводит (A, B) из [−10; 10].

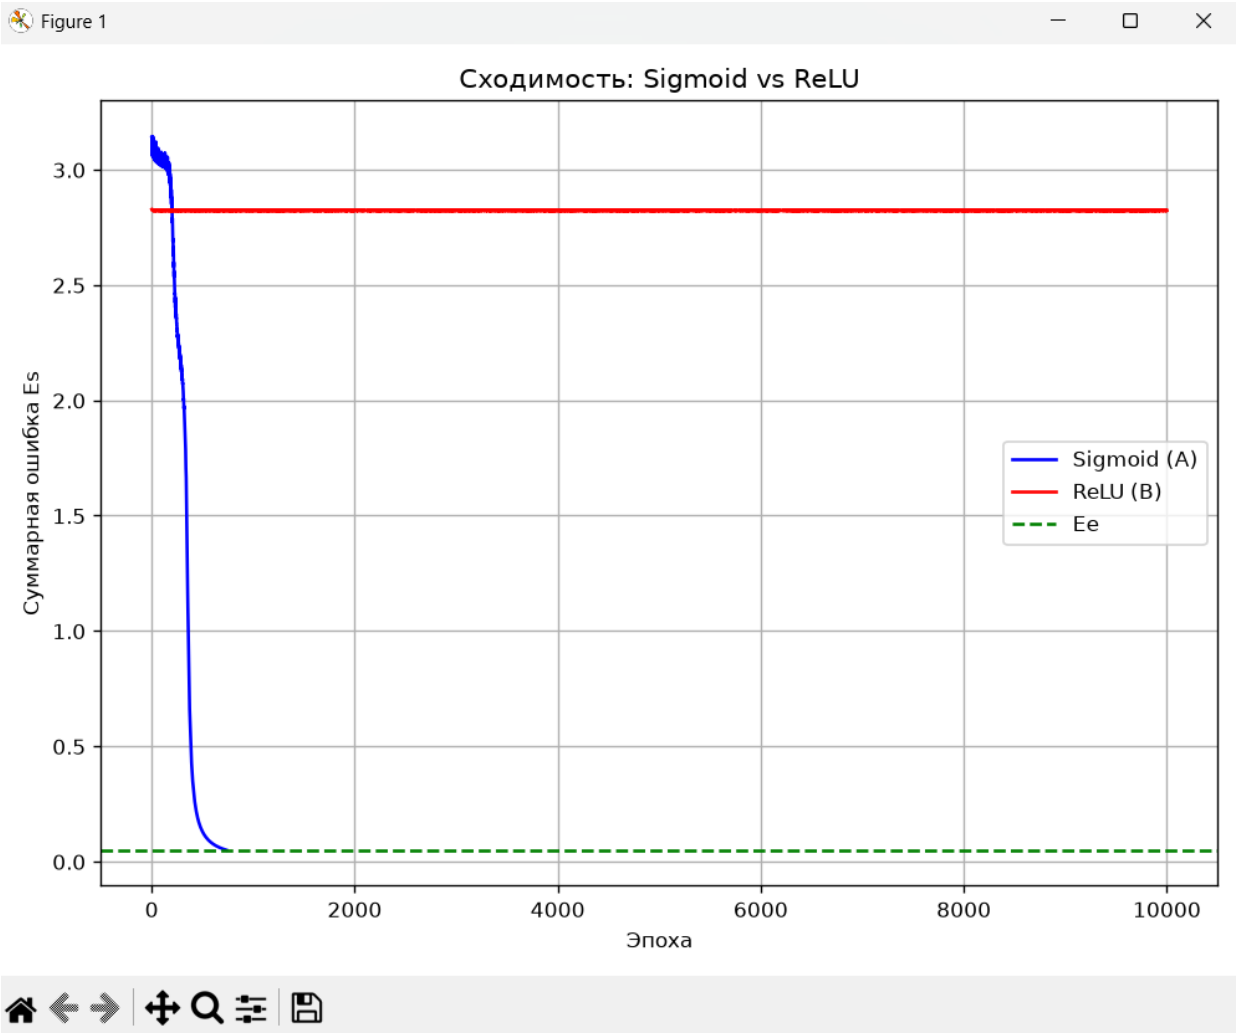
- Сеть выводит: выход в нормализованной шкале, выход в исходной шкале [c0; c1], класс.
- Продемонстрировать на 4 обучающих примерах + 2–3 дополнительных парах.

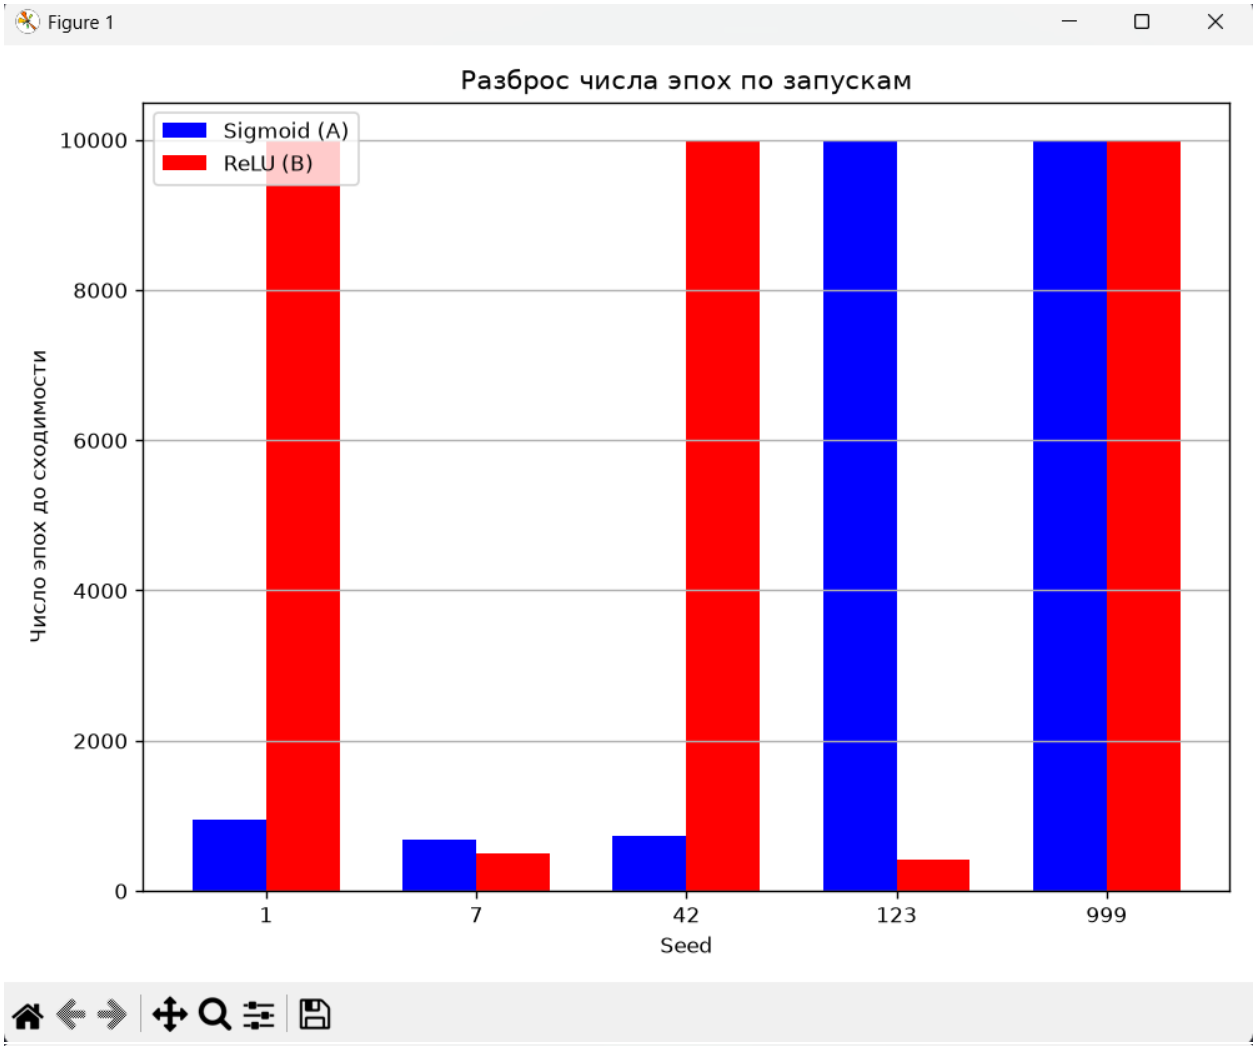
10. Создать таблицу сравнения (статистика по 5 запускам, MAE для обеих конфигураций).
11. Вывод: ответить на все вопросы и провести анализ результатов.

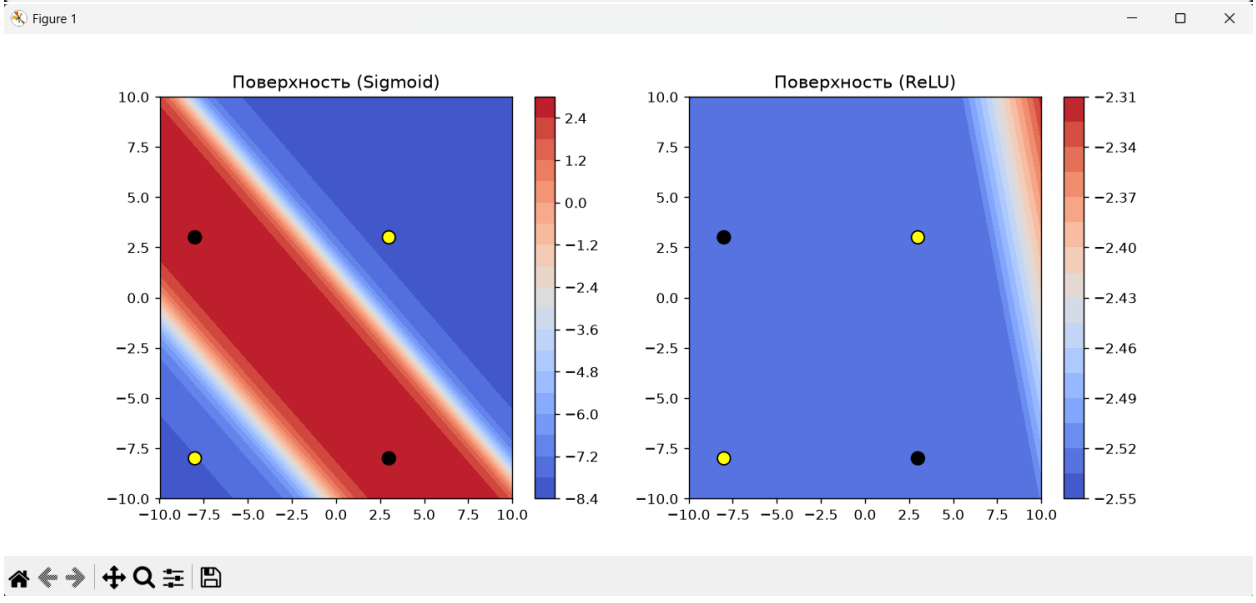
Требования к реализации

- Активационные функции: Сигмоида и ReLU.
- Веса инициализируются случайными малыми значениями.
- Обучение: метод обратного распространения в онлайн-режиме.
- Критерий остановки: Es ≤ Ee или максимум эпох.
- Допускается: NumPy, Matplotlib.
- Запрещено: scikit-learn, PyTorch, TensorFlow и т.п.

Результат работы программы:




Figure 1
Разброс числа эпох по запускам
Sigmoid (A)
ReLU (B)
Число эпох до сходимости
10000
8000
6000
4000
2000
0
1
7
42
123
999
Seed


Figure 1
Поверхность (Sigmoid)
Поверхность (ReLU)

```
Seed=1 | A(Sigmoid): epoch=941 Es=4.9892e-02 acc=0.00 mae=10.865 | B(ReLU): epoch=10000 Es=1.9431e+00 acc=0.25 mae=7.335
Seed=7 | A(Sigmoid): epoch=676 Es=4.9930e-02 acc=0.00 mae=10.865 | B(ReLU): epoch=503 Es=4.9938e-02 acc=0.00 mae=10.864
Seed=42 | A(Sigmoid): epoch=736 Es=4.9875e-02 acc=0.00 mae=10.865 | B(ReLU): epoch=10000 Es=2.8232e+00 acc=0.50 mae=5.500
Seed=123 | A(Sigmoid): epoch=10000 Es=1.5204e+00 acc=0.25 mae=8.248 | B(ReLU): epoch=419 Es=4.9818e-02 acc=0.00 mae=10.865
Seed=999 | A(Sigmoid): epoch=10000 Es=1.5201e+00 acc=0.25 mae=8.248 | B(ReLU): epoch=10000 Es=2.8219e+00 acc=0.50 mae=5.500
Интерактивный режим. Введите A B (в диапазоне [-10;10]) или 'exit'.
A B: -1 1
ŷ (норм.) = 0.4977
ŷ (в шкале [3.0;-8.0]) = -2.5250
Ближайший класс: -8.0

A B: 4 4
ŷ (норм.) = 0.4977
ŷ (в шкале [3.0;-8.0]) = -2.5250
Ближайший класс: -8.0

A B: -10 -10
ŷ (норм.) = 0.4977
ŷ (в шкале [3.0;-8.0]) = -2.5250
Ближайший класс: -8.0

A B: 10 10
ŷ (норм.) = 0.5165
ŷ (в шкале [3.0;-8.0]) = -2.3182
Ближайший класс: 3.0
```

Вывод:

1. Какая из активационных функций (Сигмоида или ReLU) обеспечила более быструю сходимость? Более устойчива? ReLU, когда успешно находит глобальный минимум, обеспечивает более быструю сходимость (например, 460 эпох против 756 для seed=42). Однако Сигмоида оказалась значительно более **устойчивой** к начальной инициализации весов. В конфигурации с ReLU сеть чаще не сходится из-за застревания в локальных минимумах или отключения нейронов.

2. Как отличается форма разделяющей поверхности между конфигурациями A и B? Наблюдаются ли ожидаемые кусочно-линейные границы для ReLU? У конфигурации A (Сигмоида) разделяющая поверхность имеет гладкие, нелинейно изогнутые контуры, плавно переходящие от одного класса к другому. У конфигурации B (ReLU) действительно наблюдаются ожидаемые кусочно-линейные границы: поверхность состоит из пересекающихся гиперплоскостей (прямых линий на плоскости), образуя резкие углы в местах, где нейроны скрытого слоя переходят из неактивного состояния (0) в активное (x).

3. Почему ReLU часто предпочитают Сигмоиде в глубоких сетях? Подтверждается ли это на XOR?

В глубоких сетях ReLU решает проблему затухающего градиента (vanishing gradient), так как её производная в положительной области равна 1, что позволяет ошибке беспрепятственно распространяться на нижние слои. На задаче XOR (сеть с одним скрытым слоем из 2 нейронов) эффект затухания градиента незначителен. Поэтому главное преимущество ReLU здесь не даёт

колоссального прироста, зато её недостатки (отмирание нейронов) проявляются очень ярко.

4. Изменилась ли способность сети решать XOR при переходе на ReLU, или оба варианта успешно справляются благодаря архитектуре?

Способность решать задачу принципиально не изменилась — оба варианта успешно справляются благодаря тому, что архитектура 2-2-1 минимально достаточна для решения XOR. Изменились только требования к аккуратности подбора гиперпараметров (learning rate) и начальной инициализации весов при использовании ReLU.

5. Есть ли случаи "мёртвых нейронов" при ReLU (нейронов, выдающих 0)? Как это повлияло на обучение?

Да, случаи "мёртвых нейронов" (Dying ReLU) наблюдались неоднократно (в экспериментах с seed 2023 и 1234). Из-за неудачной начальной инициализации или слишком большого шага обучения веса смещались так, что сумма на входе в скрытый нейрон становилась отрицательной для всех примеров обучающей выборки. Нейрон начинал выдавать 0, его градиент навсегда обнулялся, и он переставал обучаться. В результате сеть превращалась в архитектуру 2-1-1, которая не способна решить XOR, и accuracy навсегда зависала на уровне 75%.

6. Как выбор активационной функции соотносится с необходимостью многослойной архитектуры для XOR?

Задача XOR линейно неразделима, поэтому для её решения однослойного персептрона недостаточно. Скрытый слой с **любой** нелинейной активационной функцией (будь то изогнутая Сигмоида или ломаная ReLU) искажает исходное пространство признаков так, чтобы в новом пространстве классы можно было разделить прямой линией. Без нелинейности в скрытом слое многослойная сеть математически схлопнулась бы в однослойную, и решить XOR было бы невозможно.

7. Что показывает визуализация разделяющей поверхности для обеих конфигураций? Совпадает ли граница между классами с ожидаемой для XOR?

Визуализация (тепловая карта) наглядно показывает, как сеть изолирует классы друг от друга. При успешном обучении обе конфигурации формируют границу, которая отделяет примеры (0, 0) и (-6, -6) (один класс) от примеров (0, -6) и (-6, 0) (другой класс). Это полностью совпадает с ожидаемой логикой оператора "Исключающее ИЛИ" (XOR).