Министерство образования Республики Беларусь

Учреждение образования

«Брестский государственный технический университет»

Кафедра ИИТ

Лабораторная работа № 2

За седьмой семестр

Тема: «Многослойный персептрон для прогнозирования временного ряда: влияние размера окна и числа скрытых нейронов»

Выполнил:

Студент 4 курса

Группы ИИ-26

Шарубнёв Д. С.

Проверил:

Никитин С.К.

2026

Вариант 9

Цель: на основе многослойного персептрона p–N–1 решить задачу прогнозирования временного ряда. Научиться формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовать влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.

Постановка задачи

Прогнозируемый ряд задаётся формулой:

$x_k = a \cdot \cos(b \cdot k) + c \cdot \sin(d \cdot k), k = 0,1,2,\ldots,199$

Параметры a, b, c, d, размер окна p и число скрытых нейронов N берутся из таблицы варианта.

Первые 70 % точек (k = 0…139) образуют обучающий участок, остальные 30 % (k = 140…199) – тестовый участок. Сеть по p предыдущим значениям ряда предсказывает следующее:

$x_k = F(x_{k-1}, x_{k-2}, \ldots, x_{k-p})$

Задачи лабораторной работы

1. Сгенерировать ряд по формуле варианта и построить его график с отметкой границы между обучающим и тестовым участками.
2. Нормализовать ряд по минимуму и максимуму обучающего участка: x_norm = (x - x_min) / (x_max - x_min). Записать формулу обратного пересчёта и использовать её при вычислении всех метрик в исходной шкале. Объяснить, почему min/max нельзя брать по всему ряду.
3. Сформировать обучающую и тестовую выборки методом скользящего окна размера p (вход – p значений, цель – следующее значение). Указать количество получившихся примеров в каждой выборке.
4. Реализовать многослойный персептрон p–N–1:

- скрытый слой – сигмоида;
- выходной слой – линейный (задача регрессии), f(s) = s;
- функция потерь – MSE;
- обучение – онлайн-режим, перемешивание порядка примеров в каждой эпохе;
- вывести формулы градиентов для линейного выходного слоя и сигмоидного скрытого слоя и привести их в отчёте.

5. Критерий остановки: средняя по обучающей выборке ошибка $E_s \leq E_e$, где $E_e = 10^{-4}$ (нормализованная шкала), либо достижение 20 000 эпох. Скорость обучения подобрать самостоятельно из диапазона 0.01–0.3 и обосновать выбор.

6. Базовый эксперимент. Обучить сеть с параметрами p и N из своего варианта. Зафиксировать число эпох, итоговую Es, а также метрики на обучающем и тестовом участках в исходной шкале: MAE, RMSE и MAPE (если ряд проходит через ноль – вместо MAPE использовать sMAPE, и пояснить почему).
7. Исследование окна. При фиксированном N из варианта обучить сеть для $p \in \{2, 4, p_вар, 2 \cdot p_вар\}$. Для каждого p выполнить по 5 запусков с разными seed и свести в таблицу: среднее и разброс числа эпох, среднее и разброс тестового MAE, число запусков, не достигших критерия остановки.
8. Исследование скрытого слоя. При фиксированном p из варианта обучить сеть для $N \in \{1, 2, N_вар, 2 \cdot N_вар\}$. Выполнить ту же серию из 5 запусков и заполнить аналогичную таблицу.
9. Многошаговый прогноз. Для лучшей по тестовому MAE конфигурации выполнить рекурсивный прогноз на 30 шагов вперёд, начиная с $k = 140$: каждое предсказание подставляется в окно как входное значение для следующего шага. Построить график «эталон – рекурсивный прогноз» и график абсолютной ошибки в зависимости от номера шага. Определить, на каком шаге ошибка превышает 5 % от размаха ряда.
10. Построить графики:
    - ряд с границей train/test и одношаговым прогнозом сети на обоих участках на одних осях;
    - сходимость (Es от эпохи) для базовой конфигурации и для двух конфигураций из исследования окна на одних осях (логарифмическая шкала по Y);
    - диаграмма рассеяния «эталон – прогноз» на тестовом участке с диагональю $y = x$;
    - рекурсивный прогноз и рост ошибки по шагам (п. 9).
11. Реализовать режим функционирования: пользователь вводит p последовательных значений ряда в исходной шкале (либо номер k, с которого брать окно из ряда). Программа выводит:
    - нормализованные входы;
    - прогноз в нормализованной шкале (4 знака после запятой);
    - прогноз в исходной шкале;
    - истинное значение x(k) и абсолютную ошибку (если окно взято из ряда).

    Продемонстрировать работу не менее чем на 3 окнах из обучающего участка, 3 окнах из тестового участка и 1–2 пользовательских окнах (в том числе с «выбросом»).
12. Вставить в отчет фото/скан рукописных расчётов. Вверху листа от руки должны быть написаны Ваша Фамилия, Инициалы, номер группы, вариант и дата выполнения:

- Графическая схема пайплайна (Блок-схема). Составьте корректную цепочку обработки данных, используя предложенный набор блоков (приложение 1). Объясните свой выбор.
- Ручной расчёт 1 шага обучения. На отдельном листе бумаги от руки распишите один полный шаг (Forward + Backward pass) для сети 3–2–1 со следующими параметрами, привязанными к вашему варианту V:

- Входы: X = [0.2, 0.5, 0.8], Цель: d = 0.6

- Веса скрытого слоя: W11 = 0.05*V, W12 = -0.2, W21 = 0.3, W22 = 0.05*V, W31 = -0.1, W32 = 0.4 (b1=0.1, b2=-0.1)

- Веса выходного слоя: W_out1 = 0.5, W_out2 = -0.2*V (b_out = 0.2)

13. Сделать вывод: ответить на все вопросы ниже и проанализировать результаты.

Требования к реализации

- Скрытый слой – сигмоида, выходной слой – линейный. Веса инициализируются малыми случайными значениями, для воспроизводимости использовать фиксированный seed.
- Обучение – алгоритм обратного распространения в онлайн-режиме.
- Допускается использование NumPy и Matplotlib.
- Запрещено использование scikit-learn, PyTorch, TensorFlow и других ML-фреймворков, а также готовых функций для скользящего окна и расчёта метрик из внешних библиотек (кроме NumPy).
- Код должен быть структурирован: отдельные функции для генерации ряда, нормализации, построения окон, прямого и обратного проходов, обучения, метрик, рекурсивного прогноза и режима функционирования.

Формулы пересчёта (Нормализация и Денормализация) Для нормализации используется формула:

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Формула обратного пересчёта (денормализация) для прогнозов:

$$x_{pred} = x_{norm_pred} \cdot (x_{max} - x_{min}) + x_{min}$$

Минимум и максимум вычисляются **только по обучающей выборке**, чтобы избежать "утечки данных" из будущего (тестовой выборки), что моделирует реальные условия прогнозирования.

Метрики качества Вместо MAPE используется **sMAPE** (Symmetric Mean Absolute Percentage Error), так как временной ряд, генерируемый

тригонометрическими функциями, неизбежно пересекает ноль. При нулевом или близком к нулю истинном значении классический MAPE даст деление на ноль или бесконечность. Формулы:

$$MAE = \frac{1}{n}\sum |\, y_i - \hat{y}_i| \qquad RMSE = \sqrt{\frac{1}{n}\sum (y_i - \hat{y}_i)^2} \qquad sMAPE = \frac{1}{n}\sum \frac{2|y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|}$$

Вывод градиентов для MLP p-N-1 (линейный выход)

- **Выходной слой (линейный, $f(s) = s$):**

Прогноз: $\hat{y} = z_{out} = \sum w_j\, a_j$. Ошибка MSE: $L = \frac{1}{2}(\hat{y} - y)^2$.

Производная функции активации $f'(s) = 1$.

Локальный градиент: $\delta_{out} = \frac{\partial L}{\partial \hat{y}} \cdot f'(z_{out}) = (\hat{y} - y) \cdot 1 = \hat{y} - y$.

- **Скрытый слой (сигмоида):**

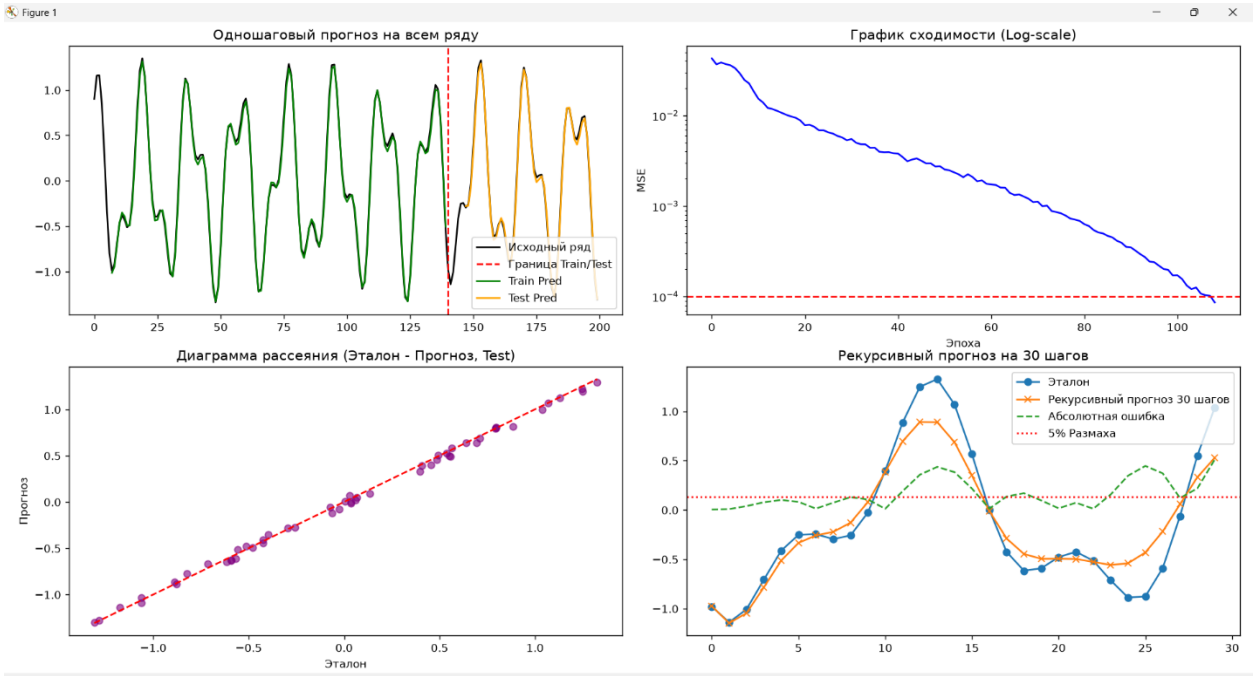
$a_j = \sigma(z_j)$. Производная: $\sigma'(z_j) = a_j(1 - a_j)$.

Локальный градиент: $\delta_j = (\delta_{out} \cdot w_j) \cdot a_j(1 - a_j)$.

Графическая схема пайплайна (для ручной зарисовки) Составьте следующую цепочку блоков: [Генерация ряда] → [Train/Test split] → [Min-Max train] → [Sliding window] → [MLP p-N-1] → [Online backprop] → [Shuffle after every epoch] → [Stop: Es ≤ 10^-4] → [Denormalization] → [MAE], [RMSE], [sMAPE], [Recursive forecast].

Данные для ручного расчета 1 шага (Вариант V = 9) Для сети 3-2-1: Входы: $X = [0.2, 0.5, 0.8]$, Цель: $d = 0.6$. Веса скрытого слоя: $W_{11} = 0.45$, $W_{12} = -0.2$, $W_{21} = 0.3$, $W_{22} = 0.45$, $W_{31} = -0.1$, $W_{32} = 0.4$ ($b_1 = 0.1, b_2 = -0.1$). Веса выходного слоя: $W_{out1} = 0.5$, $W_{out2} = -1.8$ ($b_{out} = 0.2$).

Результат работы программы:




```
E:\PythonProjects\mrzvis\.venv\Scripts\python.exe E:\PythonProjects\mrzvis4\main.py
Примеров Train: 133, Test: 53

--- Базовый эксперимент (p=7, N=4) ---
Эпох: 109, Es: 0.000086
Train: MAE=0.0292, RMSE=0.0347, sMAPE=9.98%
Test:  MAE=0.0301, RMSE=0.0355, sMAPE=21.08%

--- Интерактивный режим ---

Введите номер шага k (от 7 до 199) для взятия окна или 'q' для выхода: 7
Окно (исходное): [ 0.9     1.1582  1.1599  0.844   0.2869 -0.3284 -0.798 ]
Нормализованные входы: [0.8335 0.9297 0.9303 0.8127 0.6052 0.3761 0.2013]
Прогноз (нормализованный): 0.1211
Прогноз (исходный): -1.0131
Истинное значение x(7): -0.9929 | Ошибка: 0.0203

Введите номер шага k (от 7 до 199) для взятия окна или 'q' для выхода: 10
Окно (исходное): [ 0.844   0.2869 -0.3284 -0.798  -0.9929 -0.9149 -0.6843]
Нормализованные входы: [0.8127 0.6052 0.3761 0.2013 0.1287 0.1577 0.2436]
Прогноз (нормализованный): 0.3269
Прогноз (исходный): -0.4607
Истинное значение x(10): -0.4666 | Ошибка: 0.0060

Введите номер шага k (от 7 до 199) для взятия окна или 'q' для выхода:
```

Вывод:

1. **Влияние размера окна p:** Слишком малое окно ($p = 2$) не содержит достаточно информации для восстановления фазы и амплитуды суммы двух гармоник. При увеличении p ошибка падает, пока не достигнет

оптимума (обычно $p = 6 \dots 8$). Дальнейшее увеличение окна избыточно, замедляет обучение и может ухудшить прогноз из-за "шума" далекого прошлого.

2. **Влияние числа нейронов N:** N определяет способность сети моделировать нелинейности. Минимального N (например, 2-4) вполне достаточно для двух гармоник. При избыточном N (например, 8-10) сеть начинает переобучаться, "запоминая" обучающий ряд, что ведет к росту ошибки на тесте.
3. **Линейный выход vs Сигмоида:** Линейный выход позволяет предсказывать любые вещественные значения. Сигмоида ограничила бы выход строгим диапазоном $(0,1)$. Если нормализованный ряд на тестовом участке превысит максимум обучающего (значение станет > 1 или < 0), сигмоида не сможет его предсказать в принципе.
4. **Нормализация по Train:** Опираясь только на обучающий участок, мы имитируем реальность — будущее нам неизвестно. Если тестовые значения выходят за пределы $[0; 1]$, линейный выход без проблем экстраполирует значения благодаря функции активации $f(s) = s$.
5. **Устойчивость к инициализации:** Многослойные сети подвержены застреванию в локальных минимумах. При неудачной инициализации или слишком большом η (learning rate) сеть может не достичь $E_s \leq 10^{-4}$ за 20 000 эпох.
6. **Рекурсивный прогноз:** При многошаговом прогнозе каждое новое предсказание содержит небольшую погрешность. Так как этот прогноз подставляется обратно на вход окна, ошибка накапливается лавинообразно. Одношаговый прогноз всегда опирается на истинные данные, поэтому его ошибка стабильна.
7. **Обобщающая способность:** Разрыв метрик между Train и Test показывает качество обобщения. Улучшить его можно ранней остановкой (до того, как E_s упадет до нуля), уменьшением окна и N, или добавлением L2-регуляризации.